

Pravděpodobnost a statistika

Náhodné veličiny a jejich rozdělení

Vilém Vychodil

KMI/PRAS, Přednáška 5

Vytvořeno v rámci projektu 2963/2011 FRVŠ

Přednáška 5: Přehled

1 Náhodné veličiny a jejich rozdělení:

- náhodná veličina, inverzní obraz,
- rozdělení pravděpodobnosti náhodné veličiny,
- distribuční funkce.

2 Diskrétní náhodné veličiny:

- definice diskrétní náhodné veličiny,
- vztah k diskrétním pravděpodobnostním prostorům,
- koncentrace pravděpodobnosti, pravděpodobnostní funkce,
- Borelovské funkce, skládání náhodných veličin.

3 Očekávané hodnoty diskrétních náhodných veličin:

- definice očekávané hodnoty, operátor E ,
- střední hodnota, rozptyl, směrodatná odchylka,
- linearita operátoru E ,
- momenty, faktoriální momenty.

Opakování: Pravděpodobnostní prostory

Definice (Pravděpodobnostní míra, pravděpodobnostní prostor)

Mějme σ -algebru $\mathcal{F} \subseteq 2^\Omega$. Každé zobrazení $P: \mathcal{F} \rightarrow \mathbb{R}$ splňující

(P1) $P(A) \geq 0$ pro každou $A \in \mathcal{F}$,

(P2) $P(\Omega) = 1$,

(P3) $P(\bigcup_{i \in I} A_i) = \sum_{i \in I} P(A_i)$ pro libovolnou spočetnou $\{A_i \in \mathcal{F} \mid i \in I\}$,
kde $A_i \cap A_j = \emptyset$ pro každé $i, j \in I$ takové, že $i \neq j$ (**σ -aditivita**),

se nazývá **pravděpodobnostní míra** na \mathcal{F} a trojici $\langle \Omega, \mathcal{F}, P \rangle$ potom nazýváme **pravděpodobnostní prostor**.

Motivace:

- chceme zavést pojem jako „očekávaná hodnota“ náhodného pokusu,
- číselné hodnoty jsou přiřazeny elementárním jevům,
- vede na pojem *náhodná veličina*.

Příklad (Měření na výsledku náhodného pokusu)

Uvažujme náhodný experiment: Jsou vrženy dvě různě barevné kostky; zajímáme se o počty teček, které padnou na obou kostkách.

$$\Omega = \{\langle x, y \rangle \mid x, y \in \{1, 2, 3, 4, 5, 6\}\} = \{\langle 1, 1 \rangle, \langle 1, 2 \rangle, \dots, \langle 6, 6 \rangle\}.$$

Na Ω můžeme provést různá měření:

① součet teček na obou kostkách:

$$\langle 1, 1 \rangle \mapsto 2, \langle 1, 2 \rangle \mapsto 3, \langle 2, 1 \rangle \mapsto 3, \langle 1, 3 \rangle \mapsto 4, \langle 2, 2 \rangle \mapsto 4, \dots$$

② větší hodnota z hodnot na obou kostkách:

$$\langle 1, 1 \rangle \mapsto 1, \langle 1, 2 \rangle \mapsto 2, \langle 2, 1 \rangle \mapsto 2, \langle 1, 3 \rangle \mapsto 3, \langle 2, 2 \rangle \mapsto 2, \dots$$

③ průměr hodnot na obou kostkách:

$$\begin{aligned} \langle 1, 1 \rangle \mapsto 1, \langle 1, 2 \rangle \mapsto 1.5, \langle 2, 1 \rangle \mapsto 1.5, \langle 1, 3 \rangle \mapsto 2, \langle 2, 2 \rangle \mapsto 2, \dots \\ \vdots \end{aligned}$$

Pro výsledky měření se můžeme klást otázky typu: „Jaká hodnota je typická?“

Náhodná veličina

Definice (Náhodná veličina / náhodná proměnná)

Mějme pravděpodobnostní prostor $\langle \Omega, \mathcal{F}, P \rangle$. Zobrazení $X: \Omega \rightarrow \mathbb{R}$ nazýváme **náhodnou veličinou** v $\langle \Omega, \mathcal{F}, P \rangle$ (*angl.: random variable*) pokud

$$\{\omega \in \Omega \mid X(\omega) \leq a\} \in \mathcal{F}$$

platí pro každé $a \in \mathbb{R}$. Množinu reálných čísel $\{X(\omega) \mid \omega \in \Omega\}$ nazveme **prostor** nebo **obor hodnot** náhodné veličiny X , *angl.: space*.

Význam:

- náhodné veličiny označujeme X, Y, Z, \dots
- $X(\omega) \in \mathbb{R}$ je výsledek měření na elementárním jevu ω ,
- obor hodnot X je množina všech možných výsledků měření,
- termín „náhodná veličina“ *není příliš šťastný* (každá $X(\omega)$ je jednoznačná).

Příklady (Náhodné veličiny v témže $\langle \Omega, \mathcal{F}, P \rangle$)

Uvažujme náhodný experiment: Jsou vrženy dvě různě barevné kostky; zajímáme se počty teček, které padnou na obou kostkách.

$$\Omega = \{\langle x, y \rangle \mid x, y \in \{1, 2, 3, 4, 5, 6\}\} = \{\langle 1, 1 \rangle, \langle 1, 2 \rangle, \dots, \langle 6, 6 \rangle\}.$$

Součet teček na obou kostkách: $X: \Omega \rightarrow \mathbb{R}$ takové, že

$$X(\langle 1, 1 \rangle) = 2, X(\langle 1, 2 \rangle) = 3, X(\langle 2, 1 \rangle) = 3, X(\langle 1, 3 \rangle) = 4, X(\langle 2, 2 \rangle) = 4, \\ X(\langle 3, 1 \rangle) = 4, X(\langle 1, 4 \rangle) = 5, X(\langle 2, 3 \rangle) = 5, \dots$$

Větší hodnota z hodnot na obou kostkách: $Y: \Omega \rightarrow \mathbb{R}$ takové, že

$$Y(\langle 1, 1 \rangle) = 1, Y(\langle 1, 2 \rangle) = 2, Y(\langle 2, 1 \rangle) = 2, Y(\langle 1, 3 \rangle) = 3, Y(\langle 2, 2 \rangle) = 2, \\ Y(\langle 3, 1 \rangle) = 3, Y(\langle 1, 4 \rangle) = 4, Y(\langle 2, 3 \rangle) = 3, \dots$$

Průměr hodnot na obou kostkách: $Z: \Omega \rightarrow \mathbb{R}$ takové, že

$$Z(\langle 1, 1 \rangle) = 1, Z(\langle 1, 2 \rangle) = 1.5, Z(\langle 2, 1 \rangle) = 1.5, Z(\langle 1, 3 \rangle) = 2, Z(\langle 2, 2 \rangle) = 2, \\ Z(\langle 3, 1 \rangle) = 2, Z(\langle 1, 4 \rangle) = 2.5, Z(\langle 2, 3 \rangle) = 2.5, \dots$$

Inverzní obrazy

Definice (Inverzní obraz množiny vzhledem k X)

Mějme zobrazení $X: \Omega \rightarrow \mathbb{R}$, pak **inverzní obraz** (angl.: *inverse image*) množiny $B \subseteq \mathbb{R}$ vzhledem k zobrazení X je množina $X^{-1}(B)$ definovaná

$$X^{-1}(B) = \{\omega \in \Omega \mid X(\omega) \in B\}.$$

Inverzní obraz $B \subseteq \mathbb{R}$ vzhledem k X také označujeme $\{X \in B\}$.

Značení inverzních obrazů speciálních množin

píšeme $\{X < a\}$ místo $\{X \in (-\infty, a)\} = X^{-1}((-\infty, a))$

píšeme $\{X \leq a\}$ místo $\{X \in (-\infty, a]\} = X^{-1}((-\infty, a])$

píšeme $\{X = a\}$ místo $\{X \in \{a\}\} = X^{-1}(\{a\})$

píšeme $\{X \geq a\}$ místo $\{X \in [a, \infty)\} = X^{-1}([a, \infty))$

píšeme $\{a \leq X \leq b\}$ místo $\{X \in [a, b]\} = X^{-1}([a, b]), \dots$

Věta (O obrazech σ -algeber I)

Nechť Ω_1 a Ω_2 jsou libovolné množiny a nechť $f: \Omega_1 \rightarrow \Omega_2$ je zobrazení. Pokud je \mathcal{F}_2 σ -algebra na Ω_2 , pak $\mathcal{F}_1 = \{f^{-1}(B) \mid B \in \mathcal{F}_2\}$ je σ -algebra na Ω_1 .


Důkaz.

Platí, že $\Omega_2 \in \mathcal{F}_2$, protože \mathcal{F}_2 je σ -algebra. To znamená, že $f^{-1}(\Omega_2) = \{\omega_1 \in \Omega_1 \mid f(\omega_1) \in \Omega_2\} = \Omega_1$, tedy $\Omega_1 \in \mathcal{F}_1$.

Nechť $A \in \mathcal{F}_1$, to jest $A = f^{-1}(B)$ pro nějakou $B \in \mathcal{F}_2$.

Platí, že $\Omega_1 - A = \Omega_1 - f^{-1}(B) = \Omega_1 - \{\omega_1 \in \Omega_1 \mid f(\omega_1) \in B\} = \{\omega_1 \in \Omega_1 \mid f(\omega_1) \in \Omega_2 - B\} = f^{-1}(\Omega_2 - B)$. To jest $\Omega_1 - A = f^{-1}(\Omega_2 - B)$ pro $\Omega_2 - B \in \mathcal{F}_2$, tj. $\Omega_1 - A \in \mathcal{F}_1$.

Pro spočetně mnoho $A_i \in \mathcal{F}_1$ ($i \in I$) existují $B_i \in \mathcal{F}_2$ tak, že $A_i = f^{-1}(B_i)$. Máme $\bigcup_{i \in I} A_i = \bigcup_{i \in I} f^{-1}(B_i) = \bigcup_{i \in I} \{\omega_1 \in \Omega_1 \mid f(\omega_1) \in B_i\} = \{\omega_1 \in \Omega_1 \mid f(\omega_1) \in \bigcup_{i \in I} B_i\} = f^{-1}(\bigcup_{i \in I} B_i)$ pro $\bigcup_{i \in I} B_i \in \mathcal{F}_2$. □



Věta (O obrazech σ -algeber II)


Nechť Ω_1 a Ω_2 jsou libovolné množiny a nechť $f: \Omega_1 \rightarrow \Omega_2$ je zobrazení. Pokud je \mathcal{F}_1 σ -algebra na Ω_1 , pak $\mathcal{F}_2 = \{B \subseteq \Omega_2 \mid f^{-1}(B) \in \mathcal{F}_1\}$ je σ -algebra na Ω_2 .

Důkaz.

Platí, že $f^{-1}(\Omega_2) = \{\omega \in \Omega_1 \mid f(\omega) \in \Omega_2\} = \Omega_1 \in \mathcal{F}_1$, což prokazuje, že $\Omega_2 \in \mathcal{F}_2$.

Vezměme $B \in \mathcal{F}_2$. Dle definice \mathcal{F}_2 máme $f^{-1}(B) \in \mathcal{F}_1$. Tím pádem i $\Omega_1 - f^{-1}(B) \in \mathcal{F}_1$. To jest, $\Omega_1 - f^{-1}(B) = \Omega_1 - \{\omega \in \Omega_1 \mid f(\omega) \in B\} = \{\omega \in \Omega_1 \mid f(\omega) \in \Omega_2 - B\} = f^{-1}(\Omega_2 - B) \in \mathcal{F}_1$, což znamená $\Omega_2 - B \in \mathcal{F}_2$.

Pro spočetně mnoho $B_i \in \mathcal{F}_2$ ($i \in I$) máme $f^{-1}(B_i) \in \mathcal{F}_1$. Odtud platí, že $\bigcup_{i \in I} f^{-1}(B_i) \in \mathcal{F}_1$. To jest, $\bigcup_{i \in I} f^{-1}(B_i) = \bigcup_{i \in I} \{\omega \in \Omega_1 \mid f(\omega) \in B_i\} = \{\omega \in \Omega_1 \mid f(\omega) \in \bigcup_{i \in I} B_i\} = f^{-1}(\bigcup_{i \in I} B_i) \in \mathcal{F}_1$, tedy $\bigcup_{i \in I} B_i \in \mathcal{F}_2$. \square



Věta (Ekvivalentní zavedení náhodné veličiny)

Mějme pravděpodobnostní prostor $\langle \Omega, \mathcal{F}, P \rangle$. Zobrazení $X: \Omega \rightarrow \mathbb{R}$ je náhodná veličina v $\langle \Omega, \mathcal{F}, P \rangle$ právě tehdy, když $X^{-1}(B) \in \mathcal{F}$ platí pro každou Borelovskou množinu $B \subseteq \mathbb{R}$.

Důkaz.

Z definice náhodné veličiny, $X: \Omega \rightarrow \mathbb{R}$ je náhodná veličina právě tehdy, když $\{\omega \in \Omega \mid X(\omega) \leq a\} \in \mathcal{F}$ pro každé $a \in \mathbb{R}$, což platí právě tehdy, když $\{X \leq a\} = X^{-1}((-\infty, a]) \in \mathcal{F}$ pro každé $a \in \mathbb{R}$. Nyní prokážeme obě implikace:

„ \Rightarrow “: Položme $\mathcal{A} = \{B \subseteq \mathbb{R} \mid X^{-1}(B) \in \mathcal{F}\}$. Užitím předchozí věty dostáváme, že \mathcal{A} je σ -algebra. Jelikož je X náhodná veličina, \mathcal{A} obsahuje $(-\infty, a]$ pro každé $a \in \mathbb{R}$. Pro každý $[a, b]$ máme $[a, b] = (-\infty, a] \cap (-\infty, b] \in \mathcal{A}$, to jest \mathcal{A} je σ -algebra obsahující všechny uzavřené intervaly. Tím pádem $\mathcal{B} \subseteq \mathcal{A}$, protože σ -algebra \mathcal{B} je generovaná uzavřenými intervaly v \mathbb{R} (PŘEDNÁŠKA 3). To znamená, že každá Borelovská množina je v \mathcal{A} , tím pádem $X^{-1}(B) \in \mathcal{F}$ pro každou $B \in \mathcal{B}$.

„ \Leftarrow “: Plyne z toho, že $(-\infty, a] \subseteq \mathbb{R}$ je Borelovská pro každé $a \in \mathbb{R}$. □

Náhodné jevy spojené s náhodnými veličinami

Důsledky předchozí věty

Pro náhodnou veličinu $X: \Omega \rightarrow \mathbb{R}$ v $\langle \Omega, \mathcal{F}, P \rangle$ lze počítat pravděpodobnost

$$P(\{X \in B\}) = P(X^{-1}(B)) = P(\{\omega \in \Omega \mid X(\omega) \in B\}) ,$$

pro každou Borelovskou množinu $B \in \mathcal{B}$.

Intuitivní význam:

- provedeme opakovaně náhodný pokus a měření na jejich výsledcích;
- některé výsledky měření se budou vyskytovat častěji (mít větší relativní četnosti);
- můžeme se bavit o pravděpodobnost výskytu hodnoty X ;
- $P(\{X \in B\})$ je pravděpodobnost, že výsledek měření bude v B .

Příklad (Náhodné jevy spojené s náhodnými veličinami)

Mějme pravděpodobnostní prostor $\langle \Omega, \mathcal{F}, P \rangle$ a náhodnou veličinu $X: \Omega \rightarrow \mathbb{R}$ reprezentující výsledek měření na elementárních jevech z Ω .

Pravděpodobnosti jevů spojených s náhodnými veličinami:

- $P(\{X = a\}) = P(X^{-1}(\{a\})) = P(\{\omega \in \Omega \mid X(\omega) = a\})$
... pravděpodobnost, že hodnota X bude rovna a ,
- $P(\{X \leq a\}) = P(X^{-1}((-\infty, a])) = P(\{\omega \in \Omega \mid X(\omega) \leq a\})$
... pravděpodobnost, že hodnota X bude menší nebo rovna a ,
- $P(\{a < X < b\}) = P(X^{-1}((a, b))) = P(\{\omega \in \Omega \mid a < X(\omega) < b\})$
... pravděpodobnost, že hodnota X bude ostře mezi a a b
- $P(\{a \leq X \leq b\}) = P(X^{-1}([a, b])) = P(\{\omega \in \Omega \mid a \leq X(\omega) \leq b\})$
... pravděpodobnost, že hodnota X bude mezi a a b , ...

Příklad (Férová hra)

Jsou vrženy dvě šestistěnné kostky a spočten součet teček; pak

- vyhráváme \$10 pokud padne 2, 3, 11, nebo 12,
- prohrajeme \$10 pokud padne 7,
- v ostatních případech nevyhráváme ani neztrácíme nic.

To jest, máme klasický pravděpodobnostní prostor $\langle \Omega, 2^\Omega, P \rangle$, kde $\Omega = \{\langle 1, 1 \rangle, \dots, \langle 6, 6 \rangle\}$ a náhodnou veličinu $X: \Omega \rightarrow \mathbb{R}$ takovou, že

$$X(\langle a, b \rangle) = \begin{cases} 9, & \text{pokud } a + b \in \{2, 3, 11, 12\}, \\ -10, & \text{pokud } a + b = 7, \\ 0, & \text{jinak.} \end{cases}$$

Pro X máme:

$$\begin{aligned} P(\{X > 0\}) &= P(\{\omega \in \Omega \mid X(\omega) > 0\}) = \\ &= P(\{\langle 1, 1 \rangle, \langle 1, 2 \rangle, \langle 2, 1 \rangle, \langle 5, 6 \rangle, \langle 6, 5 \rangle, \langle 6, 6 \rangle\}) = \frac{6}{36} = \frac{1}{6}, \end{aligned}$$

$$P(\{X < 0\}) = P(\{\langle 1, 6 \rangle, \langle 6, 1 \rangle, \langle 2, 5 \rangle, \langle 5, 2 \rangle, \langle 3, 4 \rangle, \langle 4, 3 \rangle\}) = \frac{6}{36} = \frac{1}{6}.$$

Příklad (Náhodná veličina na Borelovském jevovém poli)

Mějme σ -algebru Borelovských množin $\mathcal{B} \cap 2^{[0,1]}$ na intervalu $[0, 1]$ a necht' P je Lebesgueova míra zúžená na $\mathcal{B} \cap 2^{[0,1]}$ (PŘEDNÁŠKA 3). Uvažujme zobrazení $X: [0, 1] \rightarrow \mathbb{R}$ definované $X(a) = a^2$ pro každé $a \in [0, 1]$.

Pozorování: X je náhodná veličina v $\langle [0, 1], \mathcal{B} \cap 2^{[0,1]}, P \rangle$, protože pro každé $a \in [0, 1]$ je $\{\omega \in [0, 1] \mid X(\omega) \leq a\} = \{\omega \in [0, 1] \mid \omega^2 \leq a\} = [0, \sqrt{a}]$ je Borelovská množina, to jest patří do $\mathcal{B} \cap 2^{[0,1]}$.

Úkol: Najděte hodnotu $P(\{X \in [0, 0.5)\})$.

Řešení: Nejprve stanovíme $\{X \in [0, 0.5)\}$, to jest:

$$\begin{aligned}\{X \in [0, 0.5)\} &= \{\omega \in [0, 1] \mid X(\omega) \in [0, 0.5)\} = \{\omega \in [0, 1] \mid \omega^2 \in [0, 0.5)\} \\ &= \{\omega \in \mathbb{R} \mid 0 \leq \omega^2 < 0.5\} = \{\omega \in \mathbb{R} \mid 0 \leq \omega < \sqrt{0.5}\} = [0, \sqrt{0.5}).\end{aligned}$$

Užitím faktu, že Lebesgueova míra přiřazuje intervalům jejich délku:

$$P(\{X \in [0, 0.5)\}) = P([0, \sqrt{0.5})) = \sqrt{0.5} - 0 = \sqrt{0.5}.$$

Věta (Základní vlastnosti náhodných veličin)

Pro pravděpodobnostní prostor $\langle \Omega, \mathcal{F}, P \rangle$ a zobrazení $X: \Omega \rightarrow \mathbb{R}$ platí:

- ① pokud je X konstantní, pak je X náhodná veličina v $\langle \Omega, \mathcal{F}, P \rangle$;*
- ② pokud je X náhodná veličina v $\langle \Omega, \mathcal{F}_1, P_1 \rangle$ a $\langle \Omega, \mathcal{F}_2, P_2 \rangle$ je pravděpodobnostní prostor, pro který $\mathcal{F}_1 \subseteq \mathcal{F}_2$, pak je X náhodná veličina v $\langle \Omega, \mathcal{F}_2, P_2 \rangle$.*

Důkaz.

Nechť $X(a) = c$ pro každé $a \in \Omega$. Pak pro libovolnou $B \in \mathcal{B}$ platí: (i) $\{X \in B\} = \Omega$, pokud $c \in B$; (ii) $\{X \in B\} = \emptyset$, pokud $c \notin B$. V obou případech je tedy výsledek z \mathcal{F} , což prokazuje první tvrzení.

Jelikož je X náhodná veličina v $\langle \Omega, \mathcal{F}_1, P_1 \rangle$, pro každou $B \in \mathcal{B}$ platí, že $\{X \in B\} \in \mathcal{F}_1$. Jelikož $\mathcal{F}_1 \subseteq \mathcal{F}_2$ dostáváme, že $\{X \in B\} \in \mathcal{F}_2$ pro každou $B \in \mathcal{B}$. Zbytek plyne z definice náhodné veličiny. □

Věta (O pravděpodobnostní míře indukované náhodnou veličinou)

Mějme náhodnou veličinu $X: \Omega \rightarrow \mathbb{R}$ v pravděpodobnostním prostoru $\langle \Omega, \mathcal{F}, P \rangle$. Pak zobrazení $P_X: \mathcal{B} \rightarrow \mathbb{R}$ definované $P_X(B) = P(\{X \in B\})$ je pravděpodobnostní míra na \mathcal{B} .

Důkaz.

Zřejmě $P_X(\mathbb{R}) = P(\{X \in \mathbb{R}\}) = P(X^{-1}(\mathbb{R})) = P(\Omega) = 1$. Dále platí, že $P_X(B) \geq 0$ pro každou $B \in \mathcal{B}$. Zbývá ověřit, že P_X je σ -aditivní vzhledem k \mathcal{B} . Vezměme spočetně mnoho Borelovských množin $A_i \in \mathcal{B}$ ($i \in I$) takových, že $A_i \cap A_j = \emptyset$ pro $i \neq j$. Potom

$$\begin{aligned} P_X\left(\bigcup_{i \in I} A_i\right) &= P(\{X \in \bigcup_{i \in I} A_i\}) = P(\{\omega \in \Omega \mid X(\omega) \in \bigcup_{i \in I} A_i\}) \\ &= P(\bigcup_{i \in I} \{\omega \in \Omega \mid X(\omega) \in A_i\}) = P(\bigcup_{i \in I} \{X \in A_i\}) \\ &= \sum_{i \in I} P(\{X \in A_i\}) = \sum_{i \in I} P_X(A_i), \end{aligned}$$

protože každá $\{X \in A_i\} \in \mathcal{F}$ v důsledku toho, že X je náhodná veličina a dále proto, že $\{X \in A_i\} \cap \{X \in A_j\} = \emptyset$ pro $i \neq j$, protože $A_i \cap A_j = \emptyset$. □

Rozdělení pravděpodobnosti náhodné veličiny

Definice (Rozdělení pravděpodobnosti náhodné veličiny)

Mějme pravděpodobnostní prostor $\langle \Omega, \mathcal{F}, P \rangle$ a náhodnou veličinu $X: \Omega \rightarrow \mathbb{R}$ v $\langle \Omega, \mathcal{F}, P \rangle$. Pak se pravděpodobnostní míra $P_X: \mathcal{B} \rightarrow \mathbb{R}$ na σ -algebře Borelovských množin \mathcal{B} definovaná

$$P_X(B) = P(\{X \in B\}), \quad \text{pro každou } B \in \mathcal{B}$$

nazývá **rozdělení pravděpodobnosti** náhodné veličiny X , *angl.: distribution*.

Poznámky:

- P_X je skutečně pravděpodobnostní míra (důsledek předchozí Věty);
- $\langle \mathbb{R}, \mathcal{B}, P_X \rangle$ je pravděpodobnostní prostor (indukovaný náhodnou veličinou X);
- při úvahách o pravděpodobnostech náhodných jevů spojených s náhodnými veličinami $X: \Omega \rightarrow \mathbb{R}$ často opouštíme původní pravděpodobnostní prostor $\langle \Omega, \mathcal{F}, P \rangle$ a pracujeme pouze s $\langle \mathbb{R}, \mathcal{B}, P_X \rangle$.

Příklad (Příklad různých náhodných veličin se stejným rozdělením)

Pozor: Rozdělení náhodné veličiny popisuje chování náhodné veličiny z hlediska pravděpodobnosti výskytu jejích hodnot, ale (jednoznačně) tuto náhodnou veličinu neurčuje (existuje obecně víc náhodných veličin s tímtéž rozdělením).

Například: Uvažujme náhodnou veličinu X s rozdělením P_X , kde $P_X = \delta_0$, to jest P_X je Diracova míra koncentrovaná v bodě 0, (PŘEDNÁŠKA 3).

Pak X lze chápat jako:

- konstantní zobrazení $X: \{0, 1\} \rightarrow \mathbb{R}$, kde $X(0) = X(1) = 0$;
- konstantní zobrazení $X: \{0, 1, 2\} \rightarrow \mathbb{R}$, kde $X(0) = X(1) = X(2) = 0$;
- konstantní zobrazení $X: \mathbb{R} \rightarrow \mathbb{R}$, kde $X(a) = 0$ pro každé $a \in \mathbb{R}$;
- \vdots

Pravděpodobnost rozšiřující se posloupnosti náhodných jevů

Věta

Mějme pravděpodobnostní prostor $\langle \Omega, \mathcal{F}, P \rangle$ a uvažujme posloupnost $A_1 \subseteq A_2 \subseteq A_3 \subseteq \dots$ náhodných jevů z \mathcal{F} . Pak platí:

$$P\left(\bigcup_{i=1}^{\infty} A_i\right) = \lim_{n \rightarrow \infty} P(A_n).$$

Důkaz.

Položme $B_1 = A_1$ a $B_i = A_i - A_{i-1}$ pro každé $i \geq 2$. Množiny B_i tvoří systém neslučitelných jevů. Dále platí, že $\bigcup_{i=1}^{\infty} A_i = \bigcup_{i=1}^{\infty} B_i$ a rovněž $A_n = \bigcup_{i=1}^n B_i$. S využitím σ -aditivity a definice součtu nekonečné řady:

$$\begin{aligned} P\left(\bigcup_{i=1}^{\infty} A_i\right) &= P\left(\bigcup_{i=1}^{\infty} B_i\right) = \sum_{i=1}^{\infty} P(B_i) = \lim_{n \rightarrow \infty} \sum_{i=1}^n P(B_i) \\ &= \lim_{n \rightarrow \infty} P\left(\bigcup_{i=1}^n B_i\right) = \lim_{n \rightarrow \infty} P(A_n). \end{aligned}$$



Pravděpodobnost zužující se posloupnosti náhodných jevů

Věta

Mějme pravděpodobnostní prostor $\langle \Omega, \mathcal{F}, P \rangle$ a uvažujme posloupnost $A_1 \supseteq A_2 \supseteq A_3 \supseteq \dots$ náhodných jevů z \mathcal{F} . Pak platí:

$$P\left(\bigcap_{i=1}^{\infty} A_i\right) = \lim_{n \rightarrow \infty} P(A_n).$$

Důkaz.

Na posloupnost doplňků $\Omega - A_1 \subseteq \Omega - A_2 \subseteq \Omega - A_3 \subseteq \dots$ lze aplikovat předchozí větu. Užitím De Morganových zákonů dostáváme:

$$\begin{aligned} 1 - P\left(\bigcap_{i=1}^{\infty} A_i\right) &= P\left(\Omega - \bigcap_{i=1}^{\infty} A_i\right) = P\left(\bigcup_{i=1}^{\infty} (\Omega - A_i)\right) \\ &= \lim_{n \rightarrow \infty} P(\Omega - A_n) = \lim_{n \rightarrow \infty} (1 - P(A_n)) \\ &= 1 - \lim_{n \rightarrow \infty} P(A_n), \end{aligned}$$

odtud $P\left(\bigcap_{i=1}^{\infty} A_i\right) = \lim_{n \rightarrow \infty} P(A_n)$. □

Příklad (Postupné házení mincí)

Házíme mincí tak dlouho, dokud neuvidíme stejné strany dvakrát po sobě. Zajímáme se o počet hodů, které je potřeba vykonat.

Úkol: *Jaká je pravděpodobnost, že budeme potřebovat sudý počet hodů?*

Uvažujeme náhodné jevy $A_n = \{2i \mid i = 1, \dots, n\}$, to jest:

$A_1 = \{2\}$, $A_2 = \{2, 4\}$, $A_3 = \{2, 4, 6\}, \dots$; máme:

$$P(A_1) = \frac{1}{2}, \quad P(A_2) = \frac{1}{2} + \frac{1}{8} = \frac{4+1}{8}, \quad P(A_3) = \frac{1}{2} + \frac{1}{8} + \frac{1}{32} = \frac{16+4+1}{32}, \dots$$

Užitím součtu n prvků geometrické posloupnosti máme:

$$P(A_n) = \frac{\sum_{i=0}^{n-1} 2^{2i}}{2^{2n-1}} = \frac{2 \cdot \sum_{i=0}^{n-1} 4^i}{4^n} = \frac{2 \cdot (4^n - 1)}{3 \cdot 4^n} = \frac{2}{3} \cdot \left(1 - \frac{1}{4^n}\right).$$

Užitím předchozí věty:

$$P\left(\bigcup_{i=1}^{\infty} A_i\right) = \lim_{n \rightarrow \infty} P(A_n) = \lim_{n \rightarrow \infty} \frac{2}{3} \cdot \left(1 - \frac{1}{4^n}\right) = \frac{2}{3}.$$

Distribuční funkce

Snaha o jednoduchý popis P_X :

- rozdělení P_X je zobrazení z \mathcal{B} do $[0, 1]$ (množinová funkce);
- nevýhoda: těžko si lze „představit“ nebo „zakreslit“;
- obtížná přímá analýza vlastností funkce P_X ;
- snaha o vyjádření P_X pomocí reálné funkce jedné proměnné;
- vede na pojem *distribučí funkce*:





Definice (Distribuční funkce)

Mějme náhodnou veličinu X s rozdělením P_X . Potom funkce $F_X: \mathbb{R} \rightarrow \mathbb{R}$, kde

$$F_X(x) = P_X((-\infty, x]), \quad \text{pro každé } x \in \mathbb{R}$$

se nazývá **distribuční funkce** náhodné veličiny X , *angl.: distribution function*.

Příklady (Grafy různých distribučních funkcí)



Věta (Základní vlastnosti distribuční funkce)

Nechť F_X je distribuční funkce náhodné veličiny X . Pak platí:

- ❶ *F_X je neklesající: pokud $y_1 \leq y_2$, pak $F_X(y_1) \leq F_X(y_2)$,*
- ❷ *pokud je oborem hodnot X interval $[a, b]$, pak $F_X(y) = 0$ a $F_X(z) = 1$ pro každé $y < a$ a $z \geq b$,*
- ❸ $\lim_{y \rightarrow -\infty} F_X(y) = 0$,
- ❹ $\lim_{z \rightarrow \infty} F_X(z) = 1$.

Důkaz (začátek).

První plyne monotonie pravděpodobnosti: z $y_1 \leq y_2$ dostáváme $(-\infty, y_1] \subseteq (-\infty, y_2]$, odtud $F_X(y_1) = P_X((-\infty, y_1]) \leq P((-\infty, y_2]) = F_X(y_2)$.

Dále platí $F_X(y) = P_X((-\infty, y]) = P(\{X \leq y\}) = P(\emptyset) = 0$ pro každé $y < a$. Analogicky dostaneme $F_X(z) = P(\Omega) = 1$ pro $z \geq b$.

Důkaz (dokončení).

Pro prokázání třetího tvrzení stačí ukázat, že $F_X(y_n)$ jde k nule pro každou klesající posloupnost hodnot y_n jdoucí do $-\infty$. Jelikož

$$F_X(y_n) = P_X((-\infty, y_n]) = P(\{X \leq y_n\}) = P(A_n),$$

kde $A_n = \{X \leq y_n\}$, stačí prokázat, že $P(A_n)$ jde k nule pro n rostoucí nade všechny meze. Z faktu, že A_i tvoří zužující se posloupnost náhodných jevů máme:

$$\lim_{n \rightarrow \infty} P(A_n) = P(\bigcap_{i=1}^{\infty} A_i) = P(\emptyset) = 0.$$

Poslední tvrzení se dokazuje analogicky: pro každou rostoucí posloupnost hodnot y_n jsoucí do ∞ máme $F_X(y_n) = P_X((-\infty, y_n]) = P(\{X \leq y_n\}) = P(A_n)$, kde $A_n = \{X \leq y_n\}$. Z faktu, že A_i tvoří rozšiřující se posloupnost náhodných jevů:

$$\lim_{n \rightarrow \infty} P(A_n) = P(\bigcup_{i=1}^{\infty} A_i) = P(\Omega) = 1.$$



Věta (O spojitosti F_X zprava)

Každá distribuční funkce je spojitá zprava.

Důkaz.

Prokážeme, že v každém bodě je hodnota F_X rovna hodnotě limity zprava.

Vezměme libovolnou $y \in \mathbb{R}$ a libovolnou klesající posloupnost hodnot y_n jdoucí do y . Množiny $A_n = \{X \leq y_n\}$ tvoří zužující se posloupnosti náhodných jevů, to jest $\lim_{n \rightarrow \infty} P(A_n) = P(\bigcap_{i=1}^{\infty} A_i)$. Stačí tedy prokázat, že $F_X(y) = P(\bigcap_{i=1}^{\infty} A_i)$.

Jelikož $F_X(y) = P(\{X \leq y\})$, stačí ukázat, že platí $\{X \leq y\} = \bigcap_{i=1}^{\infty} A_i$. To znamená, že stačí prokázat platnost rovnosti

$$\{\omega \in \Omega \mid X(\omega) \leq y\} = \bigcap_{i=1}^{\infty} A_i.$$

„ \subseteq “: Pokud $X(\omega) \leq y$, pak i $X(\omega) \leq y \leq y_n$ pro každé n , tudíž $\omega \in \bigcap_{i=1}^{\infty} A_i$.


„ \supseteq “: Pokud $\omega \in \bigcap_{i=1}^{\infty} A_i$, pak ω patří do každé $A_n = \{\omega \in \Omega \mid X(\omega) \leq y_n\}$, odtud $X(\omega) \leq y_n$ pro každé n , to jest $X(\omega) \leq \lim_{n \rightarrow \infty} y_n = y$. □

Příklad (F_X obecně není spojitá zleva)

Uvažujme náhodnou veličinu X s rozdělením P_X takovým, že P_X je Diracova pravděpodobnostní míra koncentrovaná v bodě 0, to jest $P_X = \delta_{x_0}$.

Podle definice Diracovy míry (PŘEDNÁŠKA 3) a z $F_X(x) = P_X((-\infty, x])$ máme

$$P_X(A) = \begin{cases} 0 & \text{pokud } 0 \notin A, \\ 1 & \text{pokud } 0 \in A, \end{cases} \quad F_X(x) = \begin{cases} 0 & \text{pokud } x < 0, \\ 1 & \text{pokud } x \geq 0. \end{cases}$$



F_X není spojitá zleva v bodě 0.

Věta (Vyjádření hodnot P_X pomocí distribuční funkce)

Mějme náhodnou veličinu X s rozdělením P_X a distribuční funkcí F_X . Pak

- ❶ $P_X((a, b]) = F_X(b) - F_X(a),$
- ❷ $P_X((a, b)) = \lim_{y \nearrow b} F_X(y) - F_X(a),$
- ❸ $P_X([a, b]) = F_X(b) - \lim_{y \nearrow a} F_X(y),$
- ❹ $P_X([a, b)) = \lim_{y \nearrow b} F_X(y) - \lim_{y \nearrow a} F_X(y),$

kde $\lim_{y \nearrow c} f(y)$ označuje limitu funkce f v bodě c zleva.

Důkaz (začátek).

V prvním případě platí, že $(a, b] = (-\infty, b] - (-\infty, a]$ a $(-\infty, a] \subseteq (-\infty, b]$.

S použitím faktu, že $P_X(A - B) = P_X(A) - P_X(A \cap B)$ dostáváme:

$$\begin{aligned} P_X((a, b]) &= P((-\infty, b] - (-\infty, a]) = P_X((-\infty, b]) - P_X((-\infty, b] \cap (-\infty, a]) \\ &= P_X((-\infty, b]) - P_X((-\infty, a]) = F_X(b) - F_X(a). \end{aligned}$$

Důkaz (dokončení).

V druhém případě využijeme faktu, že $(a, b) = \bigcup_{n=1}^{\infty} (a, b - \frac{1}{n}]$ je sjednocení rozšiřující se posloupnosti náhodných jevů a že F_X je monotonní, tedy:

$$\begin{aligned} P_X((a, b)) &= P_X\left(\bigcup_{n=1}^{\infty} (a, b - \frac{1}{n}]\right) = \lim_{n \rightarrow \infty} P_X\left((a, b - \frac{1}{n}]\right) \\ &= \lim_{n \rightarrow \infty} \left(F_X(b - \frac{1}{n}) - F_X(a)\right) = \lim_{y \nearrow b} F_X(y) - F_X(a). \end{aligned}$$

V třetím případě využijeme $[a, b] = \bigcap_{n=1}^{\infty} (a - \frac{1}{n}, b]$, to jest:

$$\begin{aligned} P_X([a, b]) &= P_X\left(\bigcap_{n=1}^{\infty} (a - \frac{1}{n}, b]\right) = \lim_{n \rightarrow \infty} P_X\left((a - \frac{1}{n}, b]\right) \\ &= \lim_{n \rightarrow \infty} \left(F_X(b) - F_X(a - \frac{1}{n})\right) = F_X(b) - \lim_{y \nearrow a} F_X(y). \end{aligned}$$

V posledním případě využijeme $[a, b) = \bigcup_{n=1}^{\infty} [a, b - \frac{1}{n}]$ a předchozího pozorování:


$$\begin{aligned} P_X([a, b)) &= P_X\left(\bigcup_{n=1}^{\infty} [a, b - \frac{1}{n}]\right) = \lim_{n \rightarrow \infty} P_X\left([a, b - \frac{1}{n}]\right) \\ &= \lim_{n \rightarrow \infty} \left(F_X(b - \frac{1}{n}) - \lim_{y \nearrow a} F_X(y)\right) \\ &= \lim_{y \nearrow b} F_X(y) - \lim_{y \nearrow a} F_X(y). \end{aligned}$$



Příklad (Vyjádření hodnot P_X pomocí distribuční funkce)

Uvažujme náhodnou veličinu X s distribuční funkcí F_X danou předpisem:

$$F_X(x) = \begin{cases} 0 & \text{pokud } x < 2, \\ 0.4 & \text{pokud } 2 \leq x < 4, \\ 1 & \text{jinak.} \end{cases}$$



Příklady:

$$P_X((0, 3)) = \lim_{y \nearrow 3} F_X(y) - F_X(0) = F_X(3) - F_X(0) = 0.4 - 0 = 0.4,$$

$$P_X((3, 4]) = F_X(4) - F_X(3) = 1 - 0.4 = 0.6,$$

$$P_X((3, 4)) = \lim_{y \nearrow 4} F_X(y) - F_X(3) = 0.4 - 0.4 = 0,$$

$$P_X([1, 5]) = F_X(5) - \lim_{y \nearrow 1} F_X(y) = F_X(5) - F_X(1) = 1 - 0 = 1,$$

$$P_X([2, 5)) = \lim_{y \nearrow 5} F_X(y) - \lim_{y \nearrow 2} F_X(y) = F_X(5) - 0 = 1 - 0 = 1.$$

Věta (Kritérium spojitosti F_X)

Mějme náhodnou veličinu X s rozdělením P_X a distribuční funkcí F_X . Distribuční funkce F_X je spojitá v bodě $a \in \mathbb{R}$ právě tehdy, když $P_X(\{a\}) = 0$.

Důkaz.

Jelikož je F_X zprava spojitá funkce, F_X je spojitá v bodě $a \in \mathbb{R}$ právě tehdy, když je F_X v bodě a zleva spojitá, což platí právě tehdy, když $F_X(a) = \lim_{y \nearrow a} F_X(y)$, to jest $F_X(a) - \lim_{y \nearrow a} F_X(y) = 0$. Z předchozí věty ale víme, že

$$P_X(\{a\}) = P_X([a, a]) = F_X(a) - \lim_{y \nearrow a} F_X(y),$$


to jest F_X je spojitá v bodě $a \in \mathbb{R}$ právě tehdy, když $P_X(\{a\}) = 0$. □

Důsledek: Následující tvrzení jsou ekvivalentní:

- distribuční funkce F_X je spojitá,
- $P_X(\{a\}) = 0$ pro každé $a \in \mathbb{R}$.

Příklad (Důsledek spojitosti F_X)

Uvažujme náhodnou veličinu X se spojitou distribuční funkcí F_X :



Ze spojitosti F_X dostáváme:

- ① $P_X((a, b]) = F_X(b) - F_X(a),$
- ② $P_X((a, b)) = \lim_{y \nearrow b} F_X(y) - F_X(a) = F_X(b) - F_X(a),$
- ③ $P_X([a, b]) = F_X(b) - \lim_{y \nearrow a} F_X(y) = F_X(b) - F_X(a),$
- ④ $P_X([a, b)) = \lim_{y \nearrow b} F_X(y) - \lim_{y \nearrow a} F_X(y) = F_X(b) - F_X(a).$

Diskrétní náhodné veličiny

Typy náhodných veličin

- rozeznáváme různé typy náhodných veličin podle jejich rozdělení;
- klademe nároky na P_X (v důsledku na F_X);
- první typ: *diskrétní náhodné veličiny* (PŘEDNÁŠKA 5 A 6);
- druhý typ: *spojité náhodné veličiny* (PŘEDNÁŠKA 7 A DALŠÍ).

Definice (Diskrétní náhodná veličina)

Náhodná veličina X s rozdělením P_X se nazývá **diskrétní** (angl.: *discrete*) pokud existuje spočetná množina $C \subseteq \mathbb{R}$ taková, že $P_X(C) = 1$.

Poznámky:

- rozdělení diskrétní náhodné veličiny je koncentrováno ve spočetně mnoha bodech;
- souvisí s pojmem **diskrétní pravděpodobnostní míra** (PŘEDNÁŠKA 3).

Charakterizace diskrétních náhodných veličin

Připomeňme (PŘEDNÁŠKA 3), že pravděpodobnostní míra $P_X: \mathcal{B} \rightarrow \mathbb{R}$ se nazývá *diskrétní* pokud existuje spočetně mnoho čísel $x_i \in \mathbb{R}$ a koeficientů $a_i \in [0, 1]$ (pro každé $i = 1, 2, \dots$) tak, že $\sum_{i=1}^{\infty} a_i = 1$ a P_X lze psát

$$P_X(A) = \sum_{i=1}^{\infty} a_i \cdot \delta_{x_i}(A),$$

kde δ_{x_i} je Diracova míra koncentrovaná v bodě x_i . Lze prokázat:

Věta (Charakterizace diskrétních náhodných veličin)

Náhodná veličina X s rozdělením P_X je diskrétní právě tehdy, když P_X je diskrétní pravděpodobnostní míra.

- diskrétní náhodné veličiny =
náhodné veličiny s rozdělením, které je diskrétní pravděpodobnostní míra;
- říkáme: „diskrétní náhodné veličiny mají diskrétní rozdělení“.

Důkaz.

Tvrzení je ve tvaru ekvivalence, prokazujeme proto obě implikace.

„ \Rightarrow “: Předpokládejme, že X je diskrétní náhodná veličina a označme C spočetnou podmnožinu \mathbb{R} pro niž $P_X(C) = 1$. Lze psát $C = \{x_1, x_2, \dots\}$, kde $x_i \neq x_j$ pro $i \neq j$. Z faktu $P_X(C) = 1$ dostáváme pro každou $B \in \mathcal{B}$:

$$\begin{aligned} P_X(B) &= P_X(B \cap C) = P_X\left(\bigcup_{k=1}^{\infty} (B \cap \{x_k\})\right) = \sum_{k=1}^{\infty} P_X(B \cap \{x_k\}) \\ &= \sum_{k=1}^{\infty} P_X(\{x_k\}) \cdot \delta_{x_k}(B). \end{aligned}$$

Užitím σ -aditivity, $1 = P_X(C) = P_X\left(\bigcup_{k=1}^{\infty} \{x_k\}\right) = \sum_{k=1}^{\infty} P_X(\{x_k\})$, takže za hledané koeficienty a_i lze vzít hodnoty $P_X(\{x_i\})$ a P_X je tím pádem diskrétní pravděpodobnostní míra.

„ \Leftarrow “: Nechť P_X je diskrétní míra ve tvaru $P_X(A) = \sum_{i=1}^{\infty} a_i \cdot \delta_{x_i}(A)$. Pak lze za hledanou $C \subseteq \mathbb{R}$ vzít spočetnou $C = \{x_1, x_2, \dots\}$. Zbývá ověřit $P_X(C) = 1$:

$$P_X(C) = \sum_{i=1}^{\infty} a_i \cdot \delta_{x_i}(C) = \sum_{i=1}^{\infty} a_i = 1.$$




Příklad (Motivace pro pravděpodobnostní funkci)

Mějme diskrétní náhodnou veličinu X jejíž rozdělení je (jednoznačně) dáno body $x_1 = 1$, $x_2 = 3$, $x_3 = 4$, a koeficienty $a_1 = 0.2$, $a_2 = 0.5$, $a_3 = 0.3$:

$$P_X(A) = \sum_{i=1}^3 a_i \cdot \delta_{x_i}(A) = 0.2 \cdot \delta_1(A) + 0.5 \cdot \delta_3(A) + 0.3 \cdot \delta_4(A).$$

$$F_X(x) = \begin{cases} 0 & \text{pokud } x < 1, \\ 0.2 & \text{pokud } 1 \leq x < 3, \\ 0.7 & \text{pokud } 3 \leq x < 4, \\ 1 & \text{pokud } x \geq 4. \end{cases}$$



Platí: $P(\{X = x_i\}) = P_X(\{x_i\}) = a_i$ a $F_X(x) = \sum \{a_i \mid x_i \leq x\}$.

Důsledek: Hodnoty F_X lze počítat jako součty (některých) hodnot $P(\{X = x_i\})$.

Pravděpodobnostní funkce

Definice (Pravděpodobnostní funkce)

Mějme diskrétní náhodnou veličinu X s rozdělením P_X . Zobrazení $f_X: \mathbb{R} \rightarrow [0, 1]$, kde $f_X(x) = P_X(\{x\})$ pro každé $x \in \mathbb{R}$, se nazývá **pravděpodobnostní funkce** f_X náhodné veličiny X , *angl.: probability mass function*.

Poznámky:

- hodnota $f_X(x)$ je rovna $P_X(\{x\}) = P(\{X = x\})$:
 - pravděpodobnost, že X nabude hodnotu x ;
 - pravděpodobnost elementárního jevu $\{x\}$ v prostoru $\langle \mathbb{R}, \mathcal{B}, P_X \rangle$.
- když je P_X koncentrovaná v x_1, x_2, \dots , pak $P_X(A) = \sum_{i=1}^{\infty} f_X(x_i) \cdot \delta_{x_i}(A)$;
- uvažujeme pouze u diskrétních náhodných veličin;
- pokud je F_X spojitá funkce, pak $P(\{X = x\}) = P_X(\{x\}) = 0$, tedy f_X by měla v každém bodě hodnotu 0 (**nezajímavé**).

Vlastnosti pravděpodobnostní funkce

Mějme diskrétní náhodnou veličinu X s rozdělením P_X , které je koncentrováno v bodech x_1, x_2, \dots , to jest, $P(\{X = y\}) = 0$ pro každé $y \notin \{x_1, x_2, \dots\}$.

Důsledky předchozích pozorování:

$$P_X(A) = \sum_{i=1}^{\infty} f_X(x_i) \cdot \delta_{x_i}(A), \quad F_X(x) = \sum_{i=1}^{\infty} f_X(x_i) \cdot \delta_{x_i}((-\infty, x]).$$

Pokud je navíc $\{x_1, x_2, \dots\} \subseteq \mathbb{N}$, pak lze pro každé $x \in \mathbb{N}$ psát:

$$P(\{X \leq x\}) = \sum_{y=1}^x f_X(y) = F_X(x), \quad P(\{X < x\}) = \sum_{y=1}^{x-1} f_X(y),$$

$$\begin{aligned} P(\{X \geq x\}) &= \sum_{y=x}^{\infty} f_X(y) \\ &= 1 - P(\{X < x\}), \end{aligned} \quad \begin{aligned} P(\{X > x\}) &= \sum_{y=x+1}^{\infty} f_X(y) \\ &= 1 - P(\{X \leq x\}). \end{aligned}$$

Příklad (Součet teček na dvou kostkách)


Jsou vrženy dvě kostky; zajímáme se o součet teček na obou kostkách.

X je náhodná veličina reprezentující „součet teček na obou kostkách“

$f_X(x)$ je pravděpodobnost, že součet teček na obou kostkách je právě x

pravděpodobnost je koncentrována v bodech z $R = \{2, 3, \dots, 12\}$

$$f_X(x) = \begin{cases} \frac{6 - |7 - x|}{36} & \text{pokud } x \in R, \\ 0 & \text{jinak.} \end{cases}$$



Příklad (Maximum z počtu teček na dvou kostkách)


Jsou vrženy dvě kostky; zajímáme se o maximum počtu teček na obou kostkách.

X je náhodná veličina reprezentující „maximum počtu teček na kostkách“





$f_X(x)$ je pravděpodobnost, že větší z počtu teček na kostkách je právě x

pravděpodobnost je koncentrována v bodech z $R = \{1, 2, \dots, 6\}$

$$f_X(x) = \begin{cases} \frac{2 \cdot x - 1}{36} & \text{pokud } x \in R, \\ 0 & \text{jinak.} \end{cases}$$



Příklady (Pravděpodobnostní a distribuční funkce)



Borelovské funkce

Definice (Borelovská funkce)

Funkce $f: \mathbb{R} \rightarrow \mathbb{R}$ se nazývá **Borelovská funkce** (angl.: *Borel function*), pokud pro každé $a \in \mathbb{R}$ platí, že $\{x \in \mathbb{R} \mid f(x) \leq a\}$ je Borelovská množina.

Poznámka: Pro $f: A \rightarrow B$ a $g: B \rightarrow C$ uvažujeme **složenou funkci** $g(f): A \rightarrow C$ (někdy značíme $f \circ g$) takovou, že $(g(f))(x) = g(f(x))$ pro každé $x \in A$.

Věta

Mějme pravděpodobnostní prostor $\langle \mathbb{R}, \mathcal{B}, P \rangle$. Pak platí:

- 1 X je náhodná veličina v $\langle \mathbb{R}, \mathcal{B}, P \rangle$ právě tehdy, když je X Borelovská funkce.
- 2 Je-li X náhodná veličina v pravděpodobnostním prostoru $\langle \Omega, \mathcal{F}, P \rangle$ a g je Borelovská funkce, pak $g(X)$ je náhodná veličina v $\langle \Omega, \mathcal{F}, P \rangle$.
- 3 Je-li X diskrétní náhodná veličina v $\langle \Omega, \mathcal{F}, P \rangle$ a g je Borelovská funkce, pak $g(X)$ je rovněž diskrétní náhodná veličina v $\langle \Omega, \mathcal{F}, P \rangle$.

Důkaz.

První tvrzení plyne přímo z definice náhodné veličiny.

Ověříme druhé tvrzení. Mějme náhodnou veličinu $X: \Omega \rightarrow \mathbb{R}$ a Borelovskou funkci $g: \mathbb{R} \rightarrow \mathbb{R}$. Evidentně, složená funkce $g(X)$ je zobrazení $g(X): \Omega \rightarrow \mathbb{R}$. Vezměme $a \in \mathbb{R}$. Jelikož je g Borelovská funkce, pro $B = \{x \in \mathbb{R} \mid g(x) \leq a\}$ máme $B \in \mathcal{B}$. Z toho, že X je náhodná veličina dostáváme $\{X \in B\} \in \mathcal{F}$, což znamená

$$\begin{aligned}\{X \in B\} &= \{\omega \in \Omega \mid X(\omega) \in B\} = \{\omega \in \Omega \mid X(\omega) \in \{x \in \mathbb{R} \mid g(x) \leq a\}\} \\ &= \{\omega \in \Omega \mid g(X(\omega)) \leq a\} \in \mathcal{F}.\end{aligned}$$

Z čehož dostáváme, že $g(X)$ je náhodná veličina v $\langle \Omega, \mathcal{F}, P \rangle$.

Ukážeme, že pokud je X diskrétní, pak je i $g(X)$ diskrétní. Předpokládáme, že existuje spočetná C tak, že $P_X(C) = 1$. Pro spočetnou $g(C) = \{g(c) \mid c \in C\}$:

$$\begin{aligned}1 &= P_X(C) = P(\{X \in C\}) = P(\{\omega \in \Omega \mid X(\omega) \in C\}) \\ &\leq P(\{\omega \in \Omega \mid g(X(\omega)) \in g(C)\}) = P_{g(X)}(g(C)).\end{aligned}$$



Příklad (Borelovské funkce)

Následující funkce jsou Borelovské:

- 1 *identita*, to jest $f: \mathbb{R} \rightarrow \mathbb{R}$, kde $f(x) = x$ pro každé $x \in \mathbb{R}$;
pro každé $a \in \mathbb{R}$ je $\{x \in \mathbb{R} \mid x \leq a\} = (-\infty, a]$ Borelovská množina;
- 2 *kvadratická funkce*, to jest $f: \mathbb{R} \rightarrow \mathbb{R}$, kde $f(x) = x^2$ pro každé $x \in \mathbb{R}$;
pro každé $a \geq 0$ je $\{x \in \mathbb{R} \mid x^2 \leq a\} = [-\sqrt{a}, \sqrt{a}]$ Borelovská množina;
pro každé $a < 0$ je $\{x \in \mathbb{R} \mid x^2 \leq a\} = \emptyset$ Borelovská množina;
- 3 $f: \mathbb{R} \rightarrow \mathbb{R}$, kde $f(x) = x^k$;
- 4 $f: \mathbb{R} \rightarrow \mathbb{R}$, kde $f(x) = x - a$;
- 5 $f: \mathbb{R} \rightarrow \mathbb{R}$, kde $f(x) = (x - a)^k; \dots$
- 6 obecně: každá spojitá funkce je Borelovská.

Funkce $f: \mathbb{R} \rightarrow \mathbb{R}$, které budeme používat budou vždy Borelovské.

Věta (O pravděpodobnostní funkci veličiny $g(X)$)

Nechť X je diskrétní náhodná veličina v $\langle \Omega, \mathcal{F}, P \rangle$, g je Borelovská funkce a $Y = g(X)$. Pak lze pravděpodobnostní funkci f_Y veličiny Y psát

$$f_Y(y) = \sum_{g(x)=y} f_X(x)$$

pro každé $y \in \mathbb{R}$.

Důkaz.

Jelikož je X diskrétní náhodná veličina, dle předchozí věty je i Y diskrétní a navíc existuje spočetná $C \subseteq \mathbb{R}$ taková, že $P_X(C) = 1$. Pro každé $y \in \mathbb{R}$ proto platí

$$\begin{aligned} f_Y(y) &= P_Y(\{y\}) = P_X(\{x \in \mathbb{R} \mid g(x) = y\}) = P_X(\{x \in \mathbb{R} \mid g(x) = y\} \cap C) \\ &= P_X(\{x \in C \mid g(x) = y\}) = \sum_{\substack{g(x)=y \\ x \in C}} P_X(\{x\}) = \sum_{g(x)=y} P_X(\{x\}) = \sum_{g(x)=y} f_X(x). \end{aligned}$$



Příklad (Pravděpodobnostní funkce veličiny $g(X)$)

Jsou vrženy dvě kostky; X označuje součet teček na obou kostkách.

Z předchozího víme, že pravděpodobnostní funkce f_X veličiny X má tvar:

$$f_X(x) = \begin{cases} \frac{6 - |7 - x|}{36} & \text{pokud } x \in \{2, 3, \dots, 12\}, \\ 0 & \text{jinak.} \end{cases}$$

Uvažujme funkci $g: \mathbb{R} \rightarrow \mathbb{R}$, která každé přirozené číslo zobrazí na jeho celočíselný zbytek po dělení číslem 5; a každé jiné číslo zobrazí na nulu.

(Příklad: $g(11) = 1, g(7) = 2, g(9) = 4, g(1.5) = 0, g(-2.3) = 0, \dots$)

Potom pro $Y = g(X)$ platí:

$$f_Y(y) = \sum_{g(x)=y} f_X(x) = \begin{cases} \frac{7}{36} & \text{pokud } y \in \{0, 1, 3, 4\}, \\ \frac{8}{36} & \text{pokud } y = 2, \\ 0 & \text{jinak.} \end{cases}$$

Příklad (Motivace pro očekávané hodnoty)

Uvažujme hazardní hru: Je vržena šestistěnná kostka a X označuje výši výplaty

$$X(s) = \begin{cases} 1 & \text{pokud } s \in \{1, 2, 3\}, \\ 5 & \text{pokud } s \in \{4, 5\}, \\ 35 & \text{pokud } s = 6. \end{cases}$$

Otázka: *Kolik si máme účtovat za jednu hru, aby byla dlouhodobě výdělečná?*

Pokud je hra hrána dlouhodobě, pak:

- zhruba polovina všech plateb bude \$1,
- zhruba jedna třetina všech plateb bude \$5,
- zhruba jedna šestina všech plateb bude \$35.

Dlouhodobá očekávaná hodnota je tedy:

$$\sum_{x=1}^6 x \cdot f_X(x) = 1 \cdot \frac{1}{2} + 5 \cdot \frac{1}{3} + 35 \cdot \frac{1}{6} = 8.$$

Za jedno kolo hry bychom měli chtít alespoň \$8.

Očekávané hodnoty

Definice (Očekávaná hodnota, angl.: *expected value*)

Mějme diskrétní náhodnou veličinu X s pravděpodobnostní funkcí f_X a označme C spočetnou podmnožinu \mathbb{R} pro niž $P_X(C) = 1$. Pokud

$$E(X) = \sum_{x \in C} x \cdot f_X(x)$$

absolutně konverguje, pak $E(X)$ nazveme **očekávaná hodnota** X . V opačném případě je očekávaná hodnota nedefinovaná.

Poznámky:

- Lze psát $E(X) = \sum_{x \in \mathbb{R}} x \cdot f_X(x)$, protože $f_X(x) = 0$ pro $x \notin C$.
- Hodnotu $E(X)$ lze chápat jako vážený průměr hodnot náhodné veličiny, kde váhy jsou funkční hodnoty f_X .
- $E(X)$ není definovaná například pokud $f_X(2^n) = 2^{-n}$ ($n \in \mathbb{N}$; nula jinak).

Věta (Očekávaná hodnota $g(X)$)

Mějme diskrétní náhodnou veličinu X s f_X a označme C spočetnou podmnožinu \mathbb{R} pro niž $P_X(C) = 1$. Pro libovolnou Borelovskou funkci $g: \mathbb{R} \rightarrow \mathbb{R}$ platí

$$E(g(X)) = \sum_{x \in C} g(x) \cdot f_X(x).$$

Důkaz.

Z předchozího víme, že $g(X)$ je diskrétní náhodná veličina koncentrovaná v bodech z $g(C) = \{g(c) \mid c \in C\}$, to jest, $P_{g(X)}(g(C)) = 1$. Dále jsme prokázali, že pro $f_{g(X)}$ platí $f_{g(X)}(y) = \sum_{g(x)=y} f_X(x)$. Nyní můžeme psát:

$$\begin{aligned} E(g(X)) &= \sum_{y \in g(C)} y \cdot f_Y(y) = \sum_{y \in g(C)} \left(y \cdot \sum_{g(x)=y} f_X(x) \right) \\ &= \sum_{y \in g(C)} \sum_{g(x)=y} y \cdot f_X(x) = \sum_{y \in g(C)} \sum_{g(x)=y} g(x) \cdot f_X(x) \\ &= \sum_{x \in C} g(x) \cdot f_X(x). \end{aligned}$$



Střední hodnota a rozptyl diskrétní náhodné veličiny

Definice (Střední hodnota, rozptyl a směrodatná odchylka)

Mějme diskrétní náhodnou veličinu X s pravděpodobnostní funkcí f_X . Pokud je očekávaná hodnota $\mu_X = E(X)$ definována, pak se nazývá **střední hodnota X** , *angl.: mean*. Pokud je očekávaná hodnota $\sigma_X^2 = E((X - \mu_X)^2)$ definována, pak se nazývá **rozptyl X** , *angl.: variance*. Druhá odmocnina $\sigma_X = \sqrt{\sigma_X^2}$ se nazývá **směrodatná odchylka X** , *angl.: standard deviation*.

Z definice očekávané hodnoty:

$$\mu_X = E(X) = \sum_{x \in \mathbb{R}} x \cdot f_X(x), \quad \sigma_X^2 = E((X - \mu_X)^2) = \sum_{x \in \mathbb{R}} (x - \mu_X)^2 \cdot f_X(x).$$

Význam:

- $E((X - \mu_X)^2)$ chápeme jako $E(g(X))$ pro Borelovskou fci. $g(x) = (x - \mu_X)^2$;
- interpretace: *střední (průměrná) hodnota X , rozptýlenost od střední hodnoty X* ;
- **teorie odhadu**: zabývá se (mimo jiné) vztahem μ_X a σ_X^2 a výběrových \bar{x} a s^2 .

Příklad (Střední hodnota a rozptyl pro házení kostkou)

Uvažujme, že X nabývá hodnot počtu teček při hodu šestistrannou kostkou.

X má pravděpodobnostní funkci f_X , pro kterou

$$f_X(x) = \begin{cases} \frac{1}{6} & \text{pokud } x \in \{1, 2, 3, 4, 5, 6\}, \\ 0 & \text{jinak.} \end{cases}$$

Střední hodnota X :

$$E(X) = \sum_{x=1}^6 x \cdot \frac{1}{6} = 1 \cdot \frac{1}{6} + 2 \cdot \frac{1}{6} + 3 \cdot \frac{1}{6} + 4 \cdot \frac{1}{6} + 5 \cdot \frac{1}{6} + 6 \cdot \frac{1}{6} = \frac{7}{2}.$$

Rozptyl X :

$$E((X - \mu_X)^2) = \sum_{x=1}^6 \left(x - \frac{7}{2}\right)^2 \cdot \frac{1}{6} = \frac{25}{24} + \frac{3}{8} + \frac{1}{24} + \frac{1}{24} + \frac{3}{8} + \frac{25}{24} = \frac{35}{12}.$$

Pozor: σ_X^2 se nerovná výběrovému rozptylu z výběru 1, 2, 3, 4, 5, 6.

Příklad (Střední hodnota a rozptyl)

Uvažujme diskrétní náhodnou veličinu X , pro kterou

$$f(x) = \begin{cases} \frac{1}{8} & \text{pro } x = 0, 3, \\ \frac{3}{8} & \text{pro } x = 1, 2, \\ 0 & \text{jinak.} \end{cases}$$

Střední hodnota X :

$$\mu_X = 0 \cdot \frac{1}{8} + 1 \cdot \frac{3}{8} + 2 \cdot \frac{3}{8} + 3 \cdot \frac{1}{8} = \frac{3}{2}.$$

Rozptyl X :

$$\sigma_X^2 = \left(0 - \frac{3}{2}\right)^2 \cdot \frac{1}{8} + \left(1 - \frac{3}{2}\right)^2 \cdot \frac{3}{8} + \left(2 - \frac{3}{2}\right)^2 \cdot \frac{3}{8} + \left(3 - \frac{3}{2}\right)^2 \cdot \frac{1}{8} = \frac{3}{4}.$$

Věta (E je lineární operátor)

Nechť $c, c_i \in \mathbb{R}$ a u, u_i jsou Borelovské funkce pro $i = 1, \dots, k$. Potom platí:

- 1 $E(c) = c$;
- 2 $E(c \cdot u(X)) = c \cdot E(u(X))$;
- 3 $E(\sum_{i=1}^k c_i \cdot u_i(X)) = \sum_{i=1}^k c_i \cdot E(u_i(X))$.

Důkaz.

Je-li c konstanta (konstantní funkce), první dvě tvrzení plynou následovně:

$$E(c) = \sum_{x \in \mathbb{R}} c \cdot f_X(x) = c \cdot \sum_{x \in \mathbb{R}} f_X(x) = c \cdot 1 = c.$$

$$E(c \cdot u(X)) = \sum_{x \in \mathbb{R}} c \cdot u(x) \cdot f_X(x) = c \cdot \sum_{x \in \mathbb{R}} u(x) \cdot f_X(x) = c \cdot E(u(X)).$$

Poslední tvrzení lze prokázat následovně:

$$\begin{aligned} E\left(\sum_{i=1}^k c_i \cdot u_i(X)\right) &= \sum_{x \in \mathbb{R}} \left(\sum_{i=1}^k c_i \cdot u_i(x)\right) \cdot f_X(x) = \sum_{x \in \mathbb{R}} \sum_{i=1}^k (c_i \cdot u_i(x) \cdot f_X(x)) \\ &= \sum_{i=1}^k c_i \cdot \sum_{x \in \mathbb{R}} (u_i(x) \cdot f_X(x)) = \sum_{i=1}^k c_i \cdot E(u_i(X)). \end{aligned}$$



Příklad (E je lineární operátor)

Uvažujme diskrétní náhodnou veličinu X s pravděpodobnostní funkcí

$$f_X(x) = \begin{cases} \frac{x}{10} & \text{pro } x \in \{1, 2, 3, 4\}, \\ 0 & \text{jinak.} \end{cases}$$

Protom máme

$$E(X) = \sum_{x=1}^4 x \cdot \frac{x}{10} = 1 \cdot \frac{1}{10} + 2 \cdot \frac{2}{10} + 3 \cdot \frac{3}{10} + 4 \cdot \frac{4}{10} = 3.$$

$$E(X^2) = \sum_{x=1}^4 x^2 \cdot \frac{x}{10} = 1 \cdot \frac{1}{10} + 4 \cdot \frac{2}{10} + 9 \cdot \frac{3}{10} + 16 \cdot \frac{4}{10} = 10.$$

$$E(X(5 - X)) = E(5X - X^2) = 5E(X) - E(X^2) = 5 \cdot 3 - 10 = 5.$$

Věta (O vztahu mezi μ_X a σ_X^2)

Mějme diskrétní náhodnou veličinu X a $b \in \mathbb{R}$. Pokud $E((X - b)^2)$ a σ_X^2 existují, pak platí $\sigma_X^2 \leq E((X - b)^2)$.

Důkaz.

Rozepsáním $E((X - b)^2)$ pomocí linearitý operátoru E dostáváme:

$$E((X - b)^2) = E(X^2 - 2bX + b^2) = E(X^2) - 2b\mu_X + b^2.$$

$E((X - b)^2)$ lze chápat jako funkci v proměnné b , označme ji h .

Vyšetříme, pro které b nabývá h svého minima:

$$h'(b) = (E(X^2) - 2b\mu_X + b^2)' = 2b - 2\mu_X.$$

Zřejmě $h'(b) = 0$ pro $b = \mu_X$. Jelikož navíc $h''(\mu_X) = 2 > 0$, μ_X je hodnota minimalizující $h(b)$. To znamená, že $h(\mu_X) = \sigma_X^2 \leq E((X - b)^2)$. □

Momenty a faktoriální momenty

Kromě μ_X a σ_X^2 uvažujeme pro X další speciální očekávané hodnoty:

Definice (Moment, faktoriální moment)

Mějme diskrétní náhodnou veličinu X a $r \in \mathbb{N}$. Pokud je očekávaná hodnota

- $E(X^r)$ definována, pak se nazývá **r -tý moment X** , *angl.: r th moment*;
- $E((X - b)^r)$ definována, pak se nazývá **r -tý moment X okolo bodu b** ;
- $E((X)_r) = E(X \cdot (X - 1) \cdot (X - 2) \cdots (X - r + 1))$ definovaná, pak se nazývá **r -tý faktoriální moment X** , *angl.: r th factorial moment*.

Speciálně pro $b = \mu_X$ se $E((X - \mu_X)^r)$ nazývá **r -tý centrální moment**.

Poznámka:

- střední modnota X = první moment X okolo bodu 0 (počátek);
- rozptyl X = druhý centrální moment X .

Věta (Vztah variance, momentů a faktoriálních momentů)

Pro každou diskrétní náhodnou veličinu X platí

❶ $\sigma_X^2 = E(X^2) - \mu_X^2,$

❷ $\sigma_X^2 = E((X)_2) + \mu_X - \mu_X^2$

Důkaz.

První rovnost se dokazuje s využitím faktu, že E je lineární operátor:

$$\begin{aligned}\sigma_X^2 &= E((X - \mu_X)^2) = E(X^2 - 2\mu_X X + \mu_X^2) = E(X^2) - 2\mu_X E(X) + \mu_X^2 \\ &= E(X^2) - 2\mu_X \cdot \mu_X + \mu_X^2 = E(X^2) - 2\mu_X^2 + \mu_X^2 = E(X^2) - \mu_X^2.\end{aligned}$$

Použitím předchozí rovnosti dostáváme:

$$\begin{aligned}E((X)_2) + \mu_X - \mu_X^2 &= E(X^2) - E(X) + \mu_X - \mu_X^2 = E(X^2) - \mu_X + \mu_X - \mu_X^2 \\ &= E(X^2) - \mu_X^2 = E((X - \mu_X)^2) = \sigma_X^2.\end{aligned}$$



Lineární transformace diskrétních náhodných veličin

Věta

Mějme diskrétní náhodné veličiny X a $Y = a \cdot X + b$, to jest $Y = g(X)$ pro $g: \mathbb{R} \rightarrow \mathbb{R}$, kde $g(x) = a \cdot x + b$. Pak platí $\mu_Y = a \cdot \mu_X + b$ a $\sigma_Y^2 = a^2 \cdot \sigma_X^2$.

Důkaz.

V prvním případě platí:

$$\mu_Y = E(Y) = E(a \cdot X + b) = a \cdot E(X) + E(b) = a \cdot E(X) + b = a \cdot \mu_X + b.$$

V druhém případě dostáváme:

$$\begin{aligned}\sigma_Y^2 &= E((Y - \mu_Y)^2) = E(((a \cdot X + b) - (a \cdot \mu_X + b))^2) \\ &= E((a \cdot X + b - a \cdot \mu_X - b)^2) = E((a \cdot X - a \cdot \mu_X)^2) \\ &= E(a^2 \cdot (X - \mu_X)^2) = a^2 \cdot E((X - \mu_X)^2) = a^2 \cdot \sigma_X^2.\end{aligned}$$



Míry šikmosti a špičatosti

Šikmost rozdělení X (angl.: *skewness*) je definována vztahem

$$\gamma_X^1 = \frac{E((X - \mu_X)^3)}{E((X - \mu_X)^2)^{\frac{3}{2}}} = \frac{E((X - \mu_X)^3)}{(\sigma_X^2)^{\frac{3}{2}}} = \frac{E((X - \mu_X)^3)}{\sigma_X^3}.$$

Špičatost rozdělení X (angl.: *kurtosis*) je definována vztahem

$$\gamma_X^2 = \frac{E((X - \mu_X)^4)}{E((X - \mu_X)^2)^2} = \frac{E((X - \mu_X)^4)}{(\sigma_X^2)^2} - 3.$$

Vlastnosti:

- $\gamma_X^1 < 0$ / $\gamma_X^1 > 0$ znamená: rozdělení X je zkoseno doprava / doleva;
- $\gamma_X^1 = 0$ znamená: rozdělení X je symetrické okolo μ_X ;
- vyšší hodnoty γ_X^2 znamenají větší „špičatost“.

Přednáška 5: Závěr

Pojmy:

- náhodná veličina, rozdělení pravděpodobnosti, distribuční funkce
- diskrétní náhodná veličina, pravděpodobnostní funkce, Borelovské funkce
- očekávaná hodnota, střední hodnota, rozptyl, směrodatná odchylka
- moment, faktoriální moment

Použité zdroje:



Capinski M., Zastawniak T. J.: *Probability Through Problems*
Springer 2001, ISBN 978-0-387-95063-1.



Hogg R. V., Tanis E. A.: *Probability and Statistical Inference*
Prentice Hall; 7. vydání 2005, ISBN 978-0-13-146413-1.



Johnson J. L.: *Probability and Statistics for Computer Science*
Wiley-Interscience 2008, ISBN 978-0-470-38342-1.