

Pravděpodobnost a statistika

Náhodné vektory

Vilém Vychodil

KMI/PRAS, Přednáška 8

Vytvořeno v rámci projektu 2963/2011 FRVŠ

Přednáška 8: Přehled

1 Náhodné vektory:

- definice náhodného vektoru, vícerozměrná Borelovská jevová pole,
- rozdělení pravděpodobnosti, borelovské funkce,
- marginální a sdružená rozdělení pravděpodobnosti, distribuční funkce,
- diskrétní a spojitá sdružená rozdělení, střední hodnoty a variance.

2 Nezávislost náhodných veličin:

- definice nezávislosti náhodných veličin, ekvivalentní vyjádření,
- nezávislost a sdružené pravděpodobností funkce a funkce hustoty,
- kovariance, korelační koeficient, lineární regrese,
- podmíněná rozdělení, distribuční funkce, očekávané hodnoty.

3 Generování pseudonáhodných čísel:

- ruletová metoda, metoda inverzní transformace,
- techniky založené na simulaci, využití funkce hustoty.

Příklad (Motivace pro náhodné vektory)

Mějme pravděpodobnostní prostor $\langle \Omega, \mathcal{F}, P \rangle$, dvě náhodné veličiny $Y: \Omega \rightarrow \mathbb{R}$ a $Z: \Omega \rightarrow \mathbb{R}$ a Borelovské množiny $A, B \in \mathcal{B}$. Zajímáme se o pravděpodobnost, že Y nabude hodnoty z množiny A a současně Z nabude hodnoty z množiny B :

$$\begin{aligned} P(\{Y \in A\} \cap \{Z \in B\}) &= P(\{\omega \in \Omega \mid Y(\omega) \in A\} \cap \{\omega \in \Omega \mid Z(\omega) \in B\}) \\ &= P(\{\omega \in \Omega \mid Y(\omega) \in A \text{ a } Z(\omega) \in B\}) \\ &= P(\{\omega \in \Omega \mid \langle Y(\omega), Z(\omega) \rangle \in A \times B\}) \\ &= P(\{\omega \in \Omega \mid \mathbf{X}(\omega) \in A \times B\}), \end{aligned}$$

kde $\mathbf{X}: \Omega \rightarrow \mathbb{R}^2$ je zobrazení definované $\mathbf{X}(\omega) = \langle Y(\omega), Z(\omega) \rangle$. Použitím standardní notace pro vyjádření inverzních obrazů

$$\{\mathbf{X} \in A \times B\} = \{\omega \in \Omega \mid \mathbf{X}(\omega) \in A \times B\},$$

můžeme psát

$$P(\{Y \in A\} \cap \{Z \in B\}) = P(\{\mathbf{X} \in A \times B\}).$$

To jest: \mathbf{X} lze chápat jako *dvourozměrnou náhodnou veličinu (náhodný vektor)*.

Náhodný vektor

Zobecnění pojmu náhodná veličina:

Definice (Náhodný vektor / vícerozměrná náhodná veličina)

Mějme pravděpodobnostní prostor $\langle \Omega, \mathcal{F}, P \rangle$. Zobrazení $\mathbf{X} : \Omega \rightarrow \mathbb{R}^n$ nazýváme (**n -rozměrný**) **náhodný vektor** v $\langle \Omega, \mathcal{F}, P \rangle$ (**angl.: random vector**) pokud

$$\{\omega \in \Omega \mid \mathbf{X}(\omega) \in (-\infty, a_1] \times \cdots \times (-\infty, a_n]\} \in \mathcal{F}.$$

platí pro každé $a_1, \dots, a_n \in \mathbb{R}$.

Poznámky:

- náhodná veličina = *jednorozměrný* náhodný vektor,
- i -tou složku $\mathbf{X}(\omega)$ označujeme $\mathbf{X}(\omega)(i)$,
- podmínku z definice lze psát $\{\omega \in \Omega \mid \mathbf{X}(\omega)(i) \leq a_i \text{ pro každé } i = 1, \dots, n\} \in \mathcal{F}$ nebo $\{\mathbf{X} \in (-\infty, a_1] \times \cdots \times (-\infty, a_n]\} \in \mathcal{F}$ pomocí inverzních obrazů.

Vícerozměrné Borelovské jevové pole

Úzce související pojem:

Definice (Vícerozměrné Borelovské jevové pole)

Mějme $\Omega = \mathbb{R}^n$ a necht'

$$\mathcal{A}^n = \{(-\infty, a_1] \times \cdots \times (-\infty, a_n] \mid a_1, \dots, a_n \in \mathbb{R}\}.$$

Pak σ -algebru $\mathcal{B}^n = \mathcal{F}_{\mathcal{A}^n}$ nazveme **n -rozměrné Borelovské (jevové) pole** a každou $A \in \mathcal{B}^n$ nazveme (**n -rozměrná**) **Borelovská množina**.

Poznámky:

- \mathcal{B}^1 je klasické Borelovské jevové pole (PŘEDNÁŠKA 3),
- motivace pro zavedení: $\{X \in B\} \in \mathcal{F}$ pro „rozumné podmnožiny“ $B \subseteq \mathbb{R}^n$
- \mathcal{B}^n má několik ekvivalentních vyjádření, ...

Věta (Ekvivalentní zavedení \mathcal{B}^n)

\mathcal{B}^n je σ -algebra generovaná $\mathcal{A}^n = \{(a_1, b_1] \times \cdots \times (a_n, b_n] \mid a_1 \leq b_1, \dots, a_n \leq b_n\}$.

Důkaz.

Nejprve prokážeme, že každá $(-\infty, a_1] \times \cdots \times (-\infty, a_n]$ náleží to $\mathcal{F}_{\mathcal{A}^n}$. To plyne z toho, že $\mathcal{F}_{\mathcal{A}^n}$ je uzavřená na sjednocení spočetně mnoha množin:

$$(-\infty, a_1] \times \cdots \times (-\infty, a_n] = \bigcup_{i=1}^{\infty} ((a_1 - i, a_1] \times \cdots \times (a_n - i, a_n]) \in \mathcal{F}_{\mathcal{A}^n}.$$

Tím jsme prokázali $\mathcal{B}^n \subseteq \mathcal{F}_{\mathcal{A}^n}$. Abychom dokázali opačnou inkluzi, stačí ověřit, že každá $(a_1, b_1] \times \cdots \times (a_n, b_n]$ náleží to \mathcal{B}^n . To prokážeme s využitím faktu, že \mathcal{B}^n je uzavřená na množinový rozdíl. Například pro $n = 2$ platí, že $(a, b] \times (c, d]$ je rovno

$$((-\infty, b] \times (-\infty, d]) - ((-\infty, b] \times (-\infty, c]) - ((-\infty, a] \times (-\infty, d]).$$

Obecně lze $(a_1, b_1] \times \cdots \times (a_n, b_n]$ vyjádřit rozdílem $n + 1$ množin ve tvaru $(-\infty, c_1] \times \cdots \times (-\infty, c_n]$, to jest $(a_1, b_1] \times \cdots \times (a_n, b_n] \in \mathcal{B}^n$. Tím jsme prokázali, že $\mathcal{F}_{\mathcal{A}^n} \subseteq \mathcal{B}^n$. Dohromady dostáváme $\mathcal{B}^n = \mathcal{F}_{\mathcal{A}^n}$. □

Věta (Generování \mathcal{B}^n pomocí jednorozměrných Borelovských množin)

\mathcal{B}^n je σ -algebra generovaná $\mathcal{A}^n = \{A_1 \times \cdots \times A_n \mid A_1, \dots, A_n \in \mathcal{B}\}$.

Důkaz.

Zřejmě platí, že každá $(-\infty, a_1] \times \cdots \times (-\infty, a_n]$ náleží do $\mathcal{F}_{\mathcal{A}^n}$, protože každá $(-\infty, a_i]$ je Borelovská množina, tedy $(-\infty, a_i] \in \mathcal{B}$. Odtud máme $\mathcal{B}^n \subseteq \mathcal{F}_{\mathcal{A}^n}$.

Vezměme libovolné $A_1, \dots, A_n \in \mathcal{B}$. Nejprve nahlédněme, že

$$\underbrace{\mathbb{R} \times \cdots \times \mathbb{R}}_{i-1} \times (a, b] \times \underbrace{\mathbb{R} \times \cdots \times \mathbb{R}}_{n-i} \in \mathcal{B}^n$$

pro každé $i = 1, \dots, n$ a $a, b \in \mathbb{R}$. To plyne z předchozího tvrzení a užitím uzavřenosti \mathcal{B}^n na sjednocení spočetně mnoha množin. Jelikož $A_i \in \mathcal{B}$ a \mathcal{B} je generovaná otevřenými intervaly, ihned dostáváme, že

$$\underbrace{\mathbb{R} \times \cdots \times \mathbb{R}}_{i-1} \times A_i \times \underbrace{\mathbb{R} \times \cdots \times \mathbb{R}}_{n-i} \in \mathcal{B}^n.$$

Fakt $A_1 \times \cdots \times A_n \in \mathcal{B}^n$ tedy plyne z uzavřenosti \mathcal{B}^n na průniky n množin. □

Věta (Ekvivalentní zavedení náhodného vektoru)

Mějme pravděpodobnostní prostor $\langle \Omega, \mathcal{F}, P \rangle$. Zobrazení $\mathbf{X} : \Omega \rightarrow \mathbb{R}^n$ je náhodný vektor v $\langle \Omega, \mathcal{F}, P \rangle$ právě tehdy, když $\{\mathbf{X} \in B\} \in \mathcal{F}$ platí pro každé $B \in \mathcal{B}^n$.

Důkaz.

Pokud $\{\mathbf{X} \in B\} \in \mathcal{F}$ platí pro každé $B \in \mathcal{B}^n$, pak je \mathbf{X} zřejmě náhodný vektor, protože $(-\infty, a_1] \times \cdots \times (-\infty, a_n] \in \mathcal{B}^n$.

Opačnou implikaci prokážeme následovně: Pro $\mathcal{A}^n = \{B \subseteq \mathbb{R}^n \mid \{\mathbf{X} \in B\} \in \mathcal{F}\}$ platí, že \mathcal{A}^n je σ -algebra (jde o obraz σ -algebry \mathcal{F} , PŘEDNÁŠKA 5). Dále platí, že \mathcal{A}^n zřejmě obsahuje všechny množiny tvaru $(-\infty, a_1] \times \cdots \times (-\infty, a_n]$, protože \mathbf{X} je náhodný vektor. Tím pádem $\mathcal{B}^n \subseteq \mathcal{A}^n$, protože \mathcal{B}^n je generovaná právě množinami v předchozím tvaru. Odtud dostáváme $\{\mathbf{X} \in B\} \in \mathcal{F}$ pro každou $B \in \mathcal{B}^n$. \square

Poznámka:

- Zobecnění věty o ekvivalentním zavedení náhodné veličiny (PŘEDNÁŠKA 5).

Rozdělení pravděpodobnosti náhodného vektoru

Definice (Rozdělení pravděpodobnosti náhodného vektoru)

Mějme pravděpodobnostní prostor $\langle \Omega, \mathcal{F}, P \rangle$ a náhodný vektor $\mathbf{X} : \Omega \rightarrow \mathbb{R}^n$ v $\langle \Omega, \mathcal{F}, P \rangle$. Pak se pravděpodobnostní míra $P_{\mathbf{X}} : \mathcal{B}^n \rightarrow \mathbb{R}$ na σ -algebře n -rozměrných Borelovských množin \mathcal{B}^n definovaná

$$P_{\mathbf{X}}(B) = P(\{\mathbf{X} \in B\}), \quad \text{pro každou } B \in \mathcal{B}^n$$

nazývá **rozdělení pravděpodobnosti** náhodného vektoru \mathbf{X} .

Poznámky:

- pro $n = 1$ je $P_{\mathbf{X}}$ rozdělení pravděpodobnosti náhodné veličiny (PŘEDNÁŠKA 5),
- pro $\mathbf{X} : \Omega \rightarrow \mathbb{R}^n$ někdy píšeme $P_{\mathbf{X}}(B_1, \dots, B_n)$ místo $P_{\mathbf{X}}(B_1 \times \dots \times B_n)$,
- místo $\langle \Omega, \mathcal{F}, P \rangle$ a $\mathbf{X} : \Omega \rightarrow \mathbb{R}^n$ se (obvykle) vedou úvahy jen v $\langle \mathbb{R}^n, \mathcal{B}^n, P_{\mathbf{X}} \rangle$.

Borelovské funkce

Definice (Borelovská funkce)

Funkce $f: \mathbb{R}^n \rightarrow \mathbb{R}$ se nazývá **Borelovská funkce** (angl.: *Borel function*), pokud pro každé $a \in \mathbb{R}$ platí, že $\{\langle x_1, \dots, x_n \rangle \in \mathbb{R}^n \mid f(x_1, \dots, x_n) \leq a\} \in \mathcal{B}^n$.

Poznámka: Pro $f: A \rightarrow B$ a $g: B \rightarrow C$ uvažujeme **složenou funkci** $g(f): A \rightarrow C$ (někdy značíme $f \circ g$) takovou, že $(g(f))(x) = g(f(x))$ pro každé $x \in A$.

Speciálně pro $f: \Omega \rightarrow \mathbb{R}^n$ a $g: \mathbb{R}^n \rightarrow \mathbb{R}$ máme $g(f): \Omega \rightarrow \mathbb{R}$.

Věta

Mějme pravděpodobnostní prostor $\langle \mathbb{R}, \mathcal{B}, P \rangle$. Pak platí:

- 1 X je náhodná veličina v $\langle \mathbb{R}^n, \mathcal{B}^n, P \rangle$ právě tehdy, když je X Borelovská funkce.
- 2 Je-li $X: \Omega \rightarrow \mathbb{R}^n$ náhodný vektor v $\langle \Omega, \mathcal{F}, P \rangle$ a $g: \mathbb{R}^n \rightarrow \mathbb{R}$ je Borelovská funkce, pak $g(X)$ je (jednorozměrná) náhodná veličina v $\langle \Omega, \mathcal{F}, P \rangle$.

Důkaz.

První tvrzení plyne přímo z definice náhodného vektoru.

Druhé tvrzení prokážeme takto: Vezměme libovolné $a \in \mathbb{R}$. Platí, že

$$\begin{aligned}\{g(\mathbf{X}) \leq a\} &= \{\omega \in \Omega \mid g(\mathbf{X}(\omega)) \leq a\} = \{\omega \in \Omega \mid \mathbf{X}(\omega) \in \{\mathbf{x} \in \mathbb{R}^n \mid g(\mathbf{x}) \leq a\}\} \\ &= \{\omega \in \Omega \mid \mathbf{X}(\omega) \in \{g \leq a\}\} = \{\mathbf{X} \in \{g \leq a\}\}.\end{aligned}$$

Jelikož g je Borelovská funkce, pak $\{g \leq a\} \in \mathcal{B}^n$. Odtud ihned dostáváme, že $\{\mathbf{X} \in \{g \leq a\}\} \in \mathcal{F}$, z čehož plyne, že $g(\mathbf{X})$ je náhodná veličina. □

Důsledek: Pro Borelovskou funkci g platí $\{g \in B\} \in \mathcal{B}^n$ pro každou $B \in \mathcal{B}$.

Příklad (Projekce jsou Borelovské funkce)

Každá **i -tá projekce** π_i , to jest zobrazení $\pi_i: \mathbb{R}^n \rightarrow \mathbb{R}$, kde $\pi_i(x_1, \dots, x_n) = x_i$ pro všechna $x_1, \dots, x_n \in \mathbb{R}$, je Borelovská funkce, protože:

$$\{\pi_i \leq a\} = \underbrace{\mathbb{R} \times \dots \times \mathbb{R}}_{i-1} \times (-\infty, a] \times \underbrace{\mathbb{R} \times \dots \times \mathbb{R}}_{n-i} \in \mathcal{B}^n.$$

Marginální náhodné veličiny a rozdělení pravděpodobnosti

S využitím projekcí můžeme zavést:

Definice (Marginální náhodná veličina a rozdělení pravděpodobnosti)

Mějme náhodný vektor $\mathbf{X}: \Omega \rightarrow \mathbb{R}^n$ s rozdělením $P_{\mathbf{X}}$, pak každá $\pi_i(\mathbf{X}): \Omega \rightarrow \mathbb{R}$ se nazývá **marginální náhodná veličina** (angl.: *marginal random variable*) a $P_{\pi_i(\mathbf{X})}$ se nazývá **marginální rozdělení pravděpodobnosti** (angl.: *marginal distribution*).

Poznámka: Podle definice lze každé rozdělení $P_{\pi_i(\mathbf{X})}: \mathcal{B} \rightarrow \mathbb{R}$ vyjádřit

$$\begin{aligned} P_{\pi_i(\mathbf{X})}(B) &= P(\{\pi_i(\mathbf{X}) \in B\}) = P(\{\mathbf{X} \in \{\pi_i \in B\}\}) = P_{\mathbf{X}}(\{\pi_i \in B\}) \\ &= P_{\mathbf{X}}(\underbrace{\mathbb{R} \times \cdots \times \mathbb{R}}_{i-1} \times B \times \underbrace{\mathbb{R} \times \cdots \times \mathbb{R}}_{n-i}), \end{aligned}$$

pro každou Borelovskou množinu $B \in \mathcal{B}$ pouze na základě znalosti $P_{\mathbf{X}}$. (!!)

V praxi obvykle známe $\langle \mathbb{R}^n, \mathcal{B}^n, P_{\mathbf{X}} \rangle$, kdežto $\langle \Omega, \mathcal{F}, P \rangle$ a $\mathbf{X}: \Omega \rightarrow \mathbb{R}^n$ jsou neznámé.

Sdružené rozdělení pravděpodobnosti

Definice (Sdružené rozdělení pravděpodobnosti)

Mějme náhodné veličiny X_1, \dots, X_n v pravděpodobnostním prostoru $\langle \Omega, \mathcal{F}, P \rangle$. Pak se zobrazení $P_{X_1, \dots, X_n} : \mathcal{B}^n \rightarrow \mathbb{R}$, pro které platí

$$P_{X_1, \dots, X_n}(A_1, \dots, A_n) = P(\{X_1 \in A_1\} \cap \dots \cap \{X_n \in A_n\})$$

pro každé $A_1, \dots, A_n \in \mathcal{B}$, nazývá **sdružené rozdělení pravděpodobnosti** náhodných veličin X_1, \dots, X_n (*angl.: joint probability distribution*).

Poznámky:

- $\{X_1 \in A_1, \dots, X_n \in A_n\}$ je zkrácená notace pro $\{X_1 \in A_1\} \cap \dots \cap \{X_n \in A_n\}$.
- Pokud známe $\langle \Omega, \mathcal{F}, P \rangle$ a $X_i : \Omega \rightarrow \mathbb{R}$ (pro každé $i = 1, \dots, n$), pak

$$P_{X_1, \dots, X_n}(A_1, \dots, A_n) = P_{\mathbf{X}}(A_1, \dots, A_n) = P(\{\mathbf{X} \in A_1 \times \dots \times A_n\}),$$

kde $\mathbf{X}(\omega)(i) = X_i(\omega)$ pro každé $i = 1, \dots, n$ a $\omega \in \Omega$.

Distribuční funkce

Definice (Distribuční funkce náhodného vektoru)

Mějme n -rozměrný náhodný vektor \mathbf{X} s rozdělením $P_{\mathbf{X}}$. Potom zobrazení $F_{\mathbf{X}}: \mathbb{R}^n \rightarrow \mathbb{R}$, definované předpisem

$$F_{\mathbf{X}}(x_1, \dots, x_n) = P_{\mathbf{X}}((-\infty, x_1], \dots, (-\infty, x_n]) \quad \text{pro každé } x_1, \dots, x_n \in \mathbb{R},$$

se nazývá **distribuční funkce** náhodného vektoru \mathbf{X} .

Poznámky:

- Pro $n = 1$ přechází v distribuční funkci F_X náhodné veličiny;
- distribuční funkce náhodných vektorů mají analogické vlastnosti jako distribuční funkce náhodných veličin (PŘEDNÁŠKA 5);
- pro dvourozměrný náhodný vektor \mathbf{X} s rozdělením $P_{\mathbf{X}}$ máme

$$\begin{aligned} \lim_{x \rightarrow \infty} F_{\mathbf{X}}(x, y) &= \lim_{x \rightarrow \infty} P_{\mathbf{X}}((-\infty, x], (-\infty, y]) = P_{\mathbf{X}}\left(\bigcup_{x=1}^{\infty} (-\infty, x] \times (-\infty, y]\right) \\ &= P_{\mathbf{X}}(\mathbb{R} \times (-\infty, y]) = P_{\pi_2(\mathbf{X})}((-\infty, y]) = F_{\pi_2(\mathbf{X})}(y). \end{aligned}$$

Marginální a sdružené distribuční funkce

Analogicky jako pro rozdělení zavádíme marginální a sdružené distribuční funkce:

Definice (Marginální distribuční funkce)

Mějme náhodný vektor $\mathbf{X} : \Omega \rightarrow \mathbb{R}^n$ s distribuční funkcí $F_{\mathbf{X}}$, pak se každá $F_{\pi_i(\mathbf{X})}$ nazývá **marginální distribuční funkce** (angl.: *marginal distribution function*).

Definice (Sdružená distribuční funkce)

Mějme náhodné veličiny X_1, \dots, X_n v pravděpodobnostním prostoru $\langle \Omega, \mathcal{F}, P \rangle$. Pak se zobrazení $F_{X_1, \dots, X_n} : \mathbb{R}^n \rightarrow \mathbb{R}$, pro které platí

$$F_{X_1, \dots, X_n}(x_1, \dots, x_n) = P(\{X_1 \leq x_1\} \cap \dots \cap \{X_n \leq x_n\}),$$

pro každé $x_1, \dots, x_n \in \mathbb{R}$, nazývá **sdružená distribuční funkce** náhodných veličin X_1, \dots, X_n (angl.: *joint distribution function*).

Diskrétní náhodné vektory

Definice (Diskrétní náhodný vektor)

Náhodný vektor $\mathbf{X} : \Omega \rightarrow \mathbb{R}^n$ s rozdělením $P_{\mathbf{X}}$ se nazývá **diskrétní** pokud existuje spočetná množina $C \subseteq \mathbb{R}^n$ taková, že $P_{\mathbf{X}}(C) = 1$.

Připomeňme (PŘEDNÁŠKA 3), že pravděpodobnostní míra $P_{\mathbf{X}} : \mathcal{B}^n \rightarrow \mathbb{R}$ se nazývá *diskrétní* pokud existuje spočetně mnoho $\mathbf{x}_i \in \mathbb{R}^n$ a koeficientů $a_i \in [0, 1]$ (pro každé $i = 1, 2, \dots$) tak, že $\sum_{i=1}^{\infty} a_i = 1$ a $P_{\mathbf{X}}$ lze psát

$$P_{\mathbf{X}}(A) = \sum_{i=1}^{\infty} a_i \cdot \delta_{\mathbf{x}_i}(A), \quad \text{pro každou } A \in \mathcal{B}^n,$$

kde $\delta_{\mathbf{x}_i} : \mathcal{B}^n \rightarrow \mathbb{R}$ je Diracova míra koncentrovaná v \mathbf{x}_i . Lze prokázat:

Věta (Charakterizace diskrétních náhodných vektorů)

Náhodný vektor \mathbf{X} s rozdělením $P_{\mathbf{X}}$ je diskrétní právě tehdy, když $P_{\mathbf{X}}$ je diskrétní pravděpodobnostní míra.

Důkaz (veden podobně u náhodných veličin, PŘEDNÁŠKA 5).

Tvrzení je ve tvaru ekvivalence, prokazujeme proto obě implikace.

„ \Rightarrow “: Předpokládejme, že X je diskrétní náhodný vektor a označme C spočetnou podmnožinu \mathbb{R}^n pro niž $P_X(C) = 1$. Lze psát $C = \{\mathbf{x}_1, \mathbf{x}_2, \dots\}$, kde $\mathbf{x}_i \neq \mathbf{x}_j$ pro $i \neq j$. Z faktu $P_X(C) = 1$ dostáváme pro každou $B \in \mathcal{B}^n$:

$$\begin{aligned} P_X(B) &= P_X(B \cap C) = P_X\left(\bigcup_{k=1}^{\infty} (B \cap \{\mathbf{x}_k\})\right) = \sum_{k=1}^{\infty} P_X(B \cap \{\mathbf{x}_k\}) \\ &= \sum_{k=1}^{\infty} P_X(\{\mathbf{x}_k\}) \cdot \delta_{\mathbf{x}_k}(B). \end{aligned}$$

Užitím σ -aditivity, $1 = P_X(C) = P_X\left(\bigcup_{k=1}^{\infty} \{\mathbf{x}_k\}\right) = \sum_{k=1}^{\infty} P_X(\{\mathbf{x}_k\})$, takže za hledané koeficienty a_i lze vzít hodnoty $P_X(\{\mathbf{x}_i\})$ a P_X je tím pádem diskrétní pravděpodobnostní míra.

„ \Leftarrow “: Nechť P_X je diskrétní míra ve tvaru $P_X(A) = \sum_{i=1}^{\infty} a_i \cdot \delta_{\mathbf{x}_i}(A)$. Pak lze za hledanou $C \subseteq \mathbb{R}^n$ vzít spočetnou $C = \{\mathbf{x}_1, \mathbf{x}_2, \dots\}$. Zbývá ověřit $P_X(C) = 1$:

$$P_X(C) = \sum_{i=1}^{\infty} a_i \cdot \delta_{\mathbf{x}_i}(C) = \sum_{i=1}^{\infty} a_i = 1.$$



Pravděpodobnostní funkce

U diskretních náhodných vektorů uvažujeme pravděpodobnostní funkce:

Definice (Pravděpodobnostní funkce)

Mějme diskretní náhodný vektor $\mathbf{X}: \Omega \rightarrow \mathbb{R}^n$ s rozdělením $P_{\mathbf{X}}$. Zobrazení $f_{\mathbf{X}}: \mathbb{R}^n \rightarrow [0, 1]$, kde $f_{\mathbf{X}}(x_1, \dots, x_n) = P_{\mathbf{X}}(\{\langle x_1, \dots, x_n \rangle\})$ pro každé $x_1, \dots, x_n \in \mathbb{R}$, se nazývá **pravděpodobnostní funkce** náhodného vektoru \mathbf{X} .

Zjednodušení: $P_{\mathbf{X}}(A)$ pro diskretní náhodný vektor \mathbf{X} lze vyjádřit

$$P_{\mathbf{X}}(A) = \sum_{\langle x_1, \dots, x_n \rangle \in A} f_{\mathbf{X}}(x_1, \dots, x_n).$$

Distribuční funkce $F_{\mathbf{X}}$ má tvar

$$\begin{aligned} F_{\mathbf{X}}(a_1, \dots, a_n) &= \sum_{x_1 \leq a_1} \cdots \sum_{x_n \leq a_n} f_{\mathbf{X}}(x_1, \dots, x_n) \\ &= \sum \{f_{\mathbf{X}}(x_1, \dots, x_n) \mid x_1 \leq a_1, \dots, x_n \leq a_n\}. \end{aligned}$$

Marginální a sdružené pravděpodobnostní funkce

Definice (Marginální a sdružené pravděpodobnostní funkce)

Mějme náhodný vektor $\mathbf{X} : \Omega \rightarrow \mathbb{R}^n$ s pravděpodobnostní funkcí $f_{\mathbf{X}}$, pak se každá $f_{\pi_i(\mathbf{X})}$ nazývá **marginální pravděpodobnostní funkce**. Mějme náhodné veličiny X_1, \dots, X_n v pravděpodobnostním prostoru $\langle \Omega, \mathcal{F}, P \rangle$. Pak se zobrazení $f_{X_1, \dots, X_n} : \mathbb{R}^n \rightarrow \mathbb{R}$, pro které platí

$$f_{X_1, \dots, X_n}(x_1, \dots, x_n) = P(\{X_1 = x_1\} \cap \dots \cap \{X_n = x_n\}),$$

pro každé $x_1, \dots, x_n \in \mathbb{R}$, nazývá **sdružená pravděpodobnostní funkce** náhodných veličin X_1, \dots, X_n .

Poznámka: Marginální pravděpodobnostní funkce lze dle definice psát ve tvaru

$$f_{\pi_i(\mathbf{X})}(x) = \sum_{x_1, \dots, x_{n-1} \in \mathbb{R}} f_{\mathbf{X}}(x_1, \dots, x_{i-1}, x, x_i, \dots, x_{n-1}).$$

Příklad (Výsledek házení dvěma kostkami)

Problém: Jsou vrženy dvě nefalšované šestistěnné kostky. Předpokládejme, že X označuje menší z výsledných hodnot a Y označuje větší z obou výsledných hodnot.

Úkol: Určete, jak vypadají sdružené a marginální pravděpodobnostní a distribuční funkce veličin X a Y .

$\frac{11}{36}$	6	$\frac{2}{36}$	$\frac{2}{36}$	$\frac{2}{36}$	$\frac{2}{36}$	$\frac{2}{36}$	$\frac{1}{36}$
$\frac{9}{36}$	5	$\frac{2}{36}$	$\frac{2}{36}$	$\frac{2}{36}$	$\frac{2}{36}$	$\frac{1}{36}$	0
$\frac{7}{36}$	4	$\frac{2}{36}$	$\frac{2}{36}$	$\frac{2}{36}$	$\frac{1}{36}$	0	0
$\frac{5}{36}$	3	$\frac{2}{36}$	$\frac{2}{36}$	$\frac{1}{36}$	0	0	0
$\frac{3}{36}$	2	$\frac{2}{36}$	$\frac{1}{36}$	0	0	0	0
$\frac{1}{36}$	1	$\frac{1}{36}$	0	0	0	0	0

		1	2	3	4	5	6
		$\frac{11}{36}$	$\frac{9}{36}$	$\frac{7}{36}$	$\frac{5}{36}$	$\frac{3}{36}$	$\frac{1}{36}$

1	6	$\frac{11}{36}$	$\frac{20}{36}$	$\frac{27}{36}$	$\frac{32}{36}$	$\frac{35}{36}$	1
$\frac{25}{36}$	5	$\frac{9}{36}$	$\frac{16}{36}$	$\frac{21}{36}$	$\frac{24}{36}$	$\frac{25}{36}$	$\frac{25}{36}$
$\frac{16}{36}$	4	$\frac{7}{36}$	$\frac{12}{36}$	$\frac{15}{36}$	$\frac{16}{36}$	$\frac{16}{36}$	$\frac{16}{36}$
$\frac{9}{36}$	3	$\frac{5}{36}$	$\frac{8}{36}$	$\frac{9}{36}$	$\frac{9}{36}$	$\frac{9}{36}$	$\frac{9}{36}$
$\frac{4}{36}$	2	$\frac{3}{36}$	$\frac{4}{36}$	$\frac{4}{36}$	$\frac{4}{36}$	$\frac{4}{36}$	$\frac{4}{36}$
$\frac{1}{36}$	1	$\frac{1}{36}$	$\frac{1}{36}$	$\frac{1}{36}$	$\frac{1}{36}$	$\frac{1}{36}$	$\frac{1}{36}$

		1	2	3	4	5	6
		$\frac{11}{36}$	$\frac{20}{36}$	$\frac{27}{36}$	$\frac{32}{36}$	$\frac{35}{36}$	1

Příklad (Vyjádření marginálních pravděpodobnostních funkcí)

Problém: Mějme náhodné veličiny X a Y , které mají sdruženou pravděpodobnostní funkci $f_{X,Y}$ danou předpisem

$$f_{X,Y}(x, y) = \frac{1}{2^{x+1}} \quad \text{pokud } x \geq y \text{ a } x, y \in \mathbb{N},$$

a $f_{X,Y}(x, y) = 0$ ve všech ostatních případech.

Úkol: Najděte marginální pravděpodobnostní funkce f_X a f_Y .

Řešení: Pomocí součtu prvků geometrické řady dostáváme:

$$f_X(x) = \sum_{y=1}^{\infty} f_{X,Y}(x, y) = \sum_{y=1}^x \frac{1}{2^{x+1}} = \frac{x}{2^{x+1}},$$

$$\begin{aligned} f_Y(y) &= \sum_{x=1}^{\infty} f_{X,Y}(x, y) = \sum_{x=y}^{\infty} \frac{1}{2^{x+1}} = \sum_{x=0}^{\infty} \frac{1}{2^{x+y+1}} = \frac{1}{2^{y+1}} \sum_{x=0}^{\infty} \frac{1}{2^x} \\ &= \frac{1}{2^{y+1}} \cdot \frac{1}{1 - \frac{1}{2}} = \frac{1}{2^{y+1}} \cdot 2 = \frac{1}{2^y}. \end{aligned}$$

Věta (O sdruženém rozdělení diskrétních náhodných veličin)

Pokud jsou X_1, \dots, X_n diskrétní veličiny, pak je jejich sdružené rozdělení pravděpodobnosti P_{X_1, \dots, X_n} diskrétní.

Důkaz.

Pokud jsou všechny X_1, \dots, X_n diskrétní náhodné veličiny, pak existují spočetné množiny $C_1, \dots, C_n \subseteq \mathbb{R}$ tak, že $P_{X_1}(C_1) = \dots = P_{X_n}(C_n) = 1$. Tedy i jejich kartézský součin $C_1 \times \dots \times C_n$ je spočetná množina. Stačí ukázat, že hledaná spočetná podmnožina \mathbb{R}^n je právě $C_1 \times \dots \times C_n$.

Pro každou C_i položme

$$D_i = \underbrace{\mathbb{R} \times \dots \times \mathbb{R}}_{i-1} \times C_i \times \underbrace{\mathbb{R} \times \dots \times \mathbb{R}}_{n-i}.$$

Jelikož $P_{X_1, \dots, X_n}(D_i) = P_{X_i}(C_i) = 1$ pro každé $i = 1, \dots, n$, dostáváme:

$$P_{X_1, \dots, X_n}(C_1 \times \dots \times C_n) = P_{X_1, \dots, X_n}(D_1 \cap \dots \cap D_n) = 1.$$



Věta (O marginálních rozděleních diskrétního sdruženého rozdělení)

Pokud je sdružené rozdělení pravděpodobnosti P_{X_1, \dots, X_n} náhodných veličin X_1, \dots, X_n diskrétní, pak jsou všechny X_1, \dots, X_n diskrétní veličiny.

Důkaz.

Nechť je sdružené rozdělení P_{X_1, \dots, X_n} diskrétní. To jest, existuje spočetná $C \subseteq \mathbb{R}^n$ tak, že $P_{X_1, \dots, X_n}(C) = 1$. Pro libovolné $i = 1, \dots, n$ položme $C_i = \{x_i \mid \langle x_1, \dots, x_n \rangle \in C\}$. Označme

$$D_i = \underbrace{\mathbb{R} \times \dots \times \mathbb{R}}_{i-1} \times C_i \times \underbrace{\mathbb{R} \times \dots \times \mathbb{R}}_{n-i}.$$

Zřejmě $C \subseteq D_i$. Z monotonie $1 = P_{X_1, \dots, X_n}(C) \leq P_{X_1, \dots, X_n}(D_i) = P_{X_i}(C_i)$, náhodná veličina X_i je tedy diskrétní, protože C_i je spočetná. □

Poznámky:

- Opačná implikace jako u předchozího tvrzení; dohromady dostáváme:
- P_{X_1, \dots, X_n} je diskrétní právě tehdy, když jsou všechny X_1, \dots, X_n diskrétní.

Absolutně spojitě sdružené rozdělení

Definice (Spojitě sdružené náhodné veličiny, angl.: *jointly continuous*)

Náhodné veličiny X_1, \dots, X_n jsou (**absolutně**) **spojitě sdružené** pokud existuje funkce $f_{X_1, \dots, X_n} : \mathbb{R}^n \rightarrow [0, \infty)$ tak, že

$$P_{X_1, \dots, X_n}((-\infty, a_1] \times \dots \times (-\infty, a_n]) = \int_{-\infty}^{a_n} \dots \int_{-\infty}^{a_1} f_{X_1, \dots, X_n}(x_1, \dots, x_n) dx_1 \dots dx_n.$$

Funkce f_{X_1, \dots, X_n} se nazývá **sdružená hustota** (angl.: *joint density*). Rozdělení pravděpodobnosti P_{X_1, \dots, X_n} se nazývá (**absolutně**) **spojitě sdružené rozdělení** (angl.: *jointly continuous probability distribution*).

Marginální hustoty: pro marginální veličinu X_i zavádíme:

$$f_{X_i}(x_i) = \underbrace{\int_{-\infty}^{\infty} \dots \int_{-\infty}^{\infty}}_{n-1} f_{X_1, \dots, X_n}(x_1, \dots, x_n) dx_1 \dots dx_{i-1} dx_{i+1} \dots dx_n.$$

Příklad (Sdružené absolutně spojité náhodné veličiny)

Mějme náhodné veličiny X a Y se sdruženou funkcí hustoty

$$f_{X,Y}(x, y) = \frac{3}{2} \cdot x^2 \cdot (1 - |y|), \quad \text{pokud } -1 < x < 1 \text{ a } -1 < y < 1,$$

a $f_{X,Y}(x, y) = 0$ jinak. Pro $A = \{\langle x, y \rangle \mid 0 < x < 1 \text{ a } 0 < y < x\}$ dostáváme

$$\begin{aligned} P_{X,Y}(A) &= \int_0^1 \int_0^x f_{X,Y}(x, y) \, dy \, dx = \int_0^1 \frac{3}{2} \cdot x^2 \cdot \int_0^x (1 - |y|) \, dy \, dx \\ &= \int_0^1 \frac{3}{2} \cdot x^2 \cdot \left[y - \frac{y^2}{2} \right]_0^x \, dx = \int_0^1 \frac{3}{2} \left(x^3 - \frac{x^4}{2} \right) \, dx = \frac{3}{2} \cdot \left[\frac{x^4}{4} - \frac{x^5}{10} \right]_0^1 = \frac{9}{40}. \end{aligned}$$

To jest,

$$P_{X,Y}(A) = P(\{\omega \in \Omega \mid 0 < X(\omega) < 1 \text{ a } 0 < Y(\omega) < X(\omega)\}) = \frac{9}{40} = 0.225.$$

Věta (O absolutně spojitých marginálních veličinách)

Mějme náhodné veličiny X a Y s absolutně spojitým sdruženým rozdělením daným sdruženou funkcí hustoty $f_{X,Y}$. Potom X a Y jsou absolutně spojitě náhodné veličiny s marginálními hustotami f_X a f_Y .

Důkaz.

Pokud je sdružené rozdělení X a Y absolutně spojitě, potom máme

$$P_X((a, b]) = P_{X,Y}((a, b] \times \mathbb{R}) = \int_a^b \left(\int_{-\infty}^{\infty} f_{X,Y}(x, y) \, dy \right) dx = \int_a^b f_X(x) \, dx,$$

$$P_Y((a, b]) = P_{X,Y}(\mathbb{R} \times (a, b]) = \int_a^b \left(\int_{-\infty}^{\infty} f_{X,Y}(x, y) \, dx \right) dy = \int_a^b f_Y(y) \, dy.$$

To znamená, že f_X a f_Y jsou funkce hustoty rozdělení veličin X a Y . □

Poznámka: Na rozdíl od diskrétních veličin, opačné tvrzení neplatí. (!!)

Příklad (Sdružené rozdělení, které není absolutně spojité)

Uvažujme absolutně spojitou náhodnou veličinu X jejíž funkce hustoty je $f_X = \mathbf{1}_{[0,1]}$. To jest, $f_X(x) = 1$ pro $x \in [0, 1]$ a $f_X(x) = 0$ ve všech ostatních případech.

Položme $Y = X$. Obě X a Y jsou *absolutně spojité náhodné veličiny*.

Uvažujme nyní $B = \{\langle x, x \rangle \mid x \in \mathbb{R}\}$. Platí

$$P(\{\langle X, Y \rangle \notin B\}) = P(\{\omega \in \Omega \mid X(\omega) \neq Y(\omega)\}) = P(\{X \neq Y\}) = 0.$$

Kdyby X a Y měly sdruženou funkci hustoty $f_{X,Y}$, pak by platilo

$$\begin{aligned} P(\{\langle X, Y \rangle \notin B\}) &= P(\{X < Y\}) + P(\{X > Y\}) \\ &= \int_{-\infty}^{\infty} \int_{-\infty}^y f_{X,Y}(x, y) \, dx \, dy + \int_{-\infty}^{\infty} \int_y^{\infty} f_{X,Y}(x, y) \, dx \, dy \\ &= \int_{-\infty}^{\infty} \int_{-\infty}^{\infty} f_{X,Y}(x, y) \, dx \, dy = P_{X,Y}(\mathbb{R}^2) = 1, \end{aligned}$$

což by byl spor s faktem, že $P(\{X \neq Y\}) = 0$; $P_{X,Y}$ proto *není absolutně spojité*.

Očekávané hodnoty

Očekávané hodnoty marginálních veličin:

- uvažujeme náhodný vektor $\mathbf{X} : \Omega \rightarrow \mathbb{R}^n$ s rozdělením $P_{\mathbf{X}}$;
- marginální veličiny $\pi_i(\mathbf{X}) : \Omega \rightarrow \mathbb{R}$ pro $i = 1, \dots, n$;
- lze uvažovat očekávané hodnoty $E(\pi_i(\mathbf{X}))$, $E(g(\pi_i(\mathbf{X})))$, \dots (PŘEDNÁŠKA 7)

Střední hodnoty marginálních veličin:

- $E(\pi_i(\mathbf{X}))$ je střední hodnota i -té marginální veličiny;
- pokud se marginální veličina označuje X , pak označujeme $E(X) = \mu_X$.

Rozptyl marginálních veličin:

- $E((\pi_i(\mathbf{X}) - E(\pi_i(\mathbf{X})))^2)$ je rozptyl i -té marginální veličiny;
- pokud je marginální veličina X , píšeme $E((X - \mu_X)^2) = \sigma_X^2 = \text{Var}(X)$.

Příklad (Motivace pro nezávislost náhodných veličin)

Uvažujme dvě náhodné veličiny X a Y v pravděpodobnostním prostoru $\langle \Omega, \mathcal{F}, P \rangle$. Pro libovolné $A, B \in \mathcal{B}$ platí, že $\{X \in A\} \in \mathcal{F}$ a $\{Y \in B\} \in \mathcal{F}$. Podle definice *nezávislosti náhodných jevů* (PŘEDNÁŠKA 4) platí, že $\{X \in A\}$ a $\{Y \in B\}$ pokud

$$P(\{X \in A\} \cap \{Y \in B\}) = P(\{X \in A\}) \cdot P(\{Y \in B\}).$$

Pomocí sdružených a marginálních rozdělání lze předchozí vyjádřit jako

$$P_{X,Y}(A, B) = P_X(A) \cdot P_Y(B).$$

Pokud $P_Y(B) > 0$, lze v důsledku nezávislosti $\{X \in A\}$ a $\{Y \in B\}$ psát

$$P(\{X \in A\} | \{Y \in B\}) = \frac{P(\{X \in A\} \cap \{Y \in B\})}{P(\{Y \in B\})} = \frac{P_{X,Y}(A, B)}{P_Y(B)} = P_X(A).$$

Rozšíření úvahy: Místo nezávislosti náhodných jevů $\{X \in A\}$ a $\{Y \in B\}$ daných dvěma konkrétními Borelovskými množinami $A, B \in \mathcal{B}$ můžeme uvažovat nezávislosti jevů pro libovolné A, B, \dots

Nezávislost náhodných veličin

Definice (Nezávislost náhodných veličin)

Mějme náhodné veličiny X_1, \dots, X_n v pravděpodobnostním prostoru $\langle \Omega, \mathcal{F}, P \rangle$. Pak X_1, \dots, X_n se nazývají **nezávislé** (angl.: *independent*) náhodné veličiny pokud

$$\{X_1 \leq a_1\}, \dots, \{X_n \leq a_n\}$$

jsou vzájemně nezávislé náhodné jevy pro každé $a_1, \dots, a_n \in \mathbb{R}$. V opačném případě se X_1, \dots, X_n nazývají **závislé** (angl.: *dependent*).

Důsledky nezávislosti: Mějme nezávislé náhodné veličiny X_1, \dots, X_n . Pak pro sdruženou pravděpodobnostní míru P_{X_1, \dots, X_n} platí

$$\begin{aligned} P_{X_1, \dots, X_n}((-\infty, a_1] \times \dots \times (-\infty, a_n]) &= P(\{X_1 \leq a_1\} \cap \dots \cap \{X_n \leq a_n\}) \\ &= \prod_{i=1}^n P(\{X_i \leq a_i\}) = \prod_{i=1}^n P_{X_i}((-\infty, a_i]). \end{aligned}$$

V případě nezávislých veličin lze vyjádřit P_{X_1, \dots, X_n} z marginálních pravděpodobností.

Věta (Ekvivalentní zavedení nezávislosti náhodných veličin)

Náhodné veličiny X_1, \dots, X_n v pravděpodobnostním prostoru $\langle \Omega, \mathcal{F}, P \rangle$ jsou nezávislé právě tehdy, když $\{X_1 \in A_1\}, \dots, \{X_n \in A_n\}$ jsou vzájemně nezávislé náhodné jevy pro všechny Borelovské množiny $A_1, \dots, A_n \in \mathcal{B}$.

Důkaz.

Prokážeme pouze netriviální implikaci pro náhodné veličiny X a Y (tvrzení pro X_1, \dots, X_n lze získat přímočarým zobecněním). Předpokládejme, že X a Y jsou nezávislé veličiny. Položme

$$\mathcal{X} = \{A \in \mathcal{B} \mid \{X \in A\} \text{ a } \{Y \leq b\} \text{ jsou nezávislé pro každé } b \in \mathbb{R}\}.$$

Dle předpokladu, $(-\infty, a] \in \mathcal{X}$ pro každé $a \in \mathbb{R}$. Navíc platí, že \mathcal{X} je uzavřená na komplement, sjednocení spočetně mnoha prvků z \mathcal{X} a $\mathbb{R} \in \mathcal{X}$ (PŘEDNÁŠKA 4). Odtud ihned dostáváme, že \mathcal{X} je σ -algebra a je totožná s \mathcal{B} . Analogicky:

$$\mathcal{Y} = \{B \in \mathcal{B} \mid \{X \in A\} \text{ a } \{Y \in B\} \text{ jsou nezávislé pro každé } A \in \mathcal{X}\}.$$

Opět máme $\mathcal{Y} = \mathcal{B}$. Pro $A, B \in \mathcal{B}$ tedy tvrzení platí, protože $A \in \mathcal{X}$, $B \in \mathcal{Y}$. □

Věta (Nezávislost odvozených náhodných veličin)

Mějme náhodné veličiny X_1, \dots, X_n v pravděpodobnostním prostoru $\langle \Omega, \mathcal{F}, P \rangle$ a Borelovské funkce g_1, \dots, g_n . Pokud jsou X_1, \dots, X_n nezávislé, pak jsou náhodné veličiny $g_1(X_1), \dots, g_n(X_n)$ rovněž nezávislé.

Důkaz.

Vezměme $a_1, \dots, a_n \in \mathbb{R}$. Stačí ukázat, že $\{g_1(X_1) \leq a_1\}, \dots, \{g_n(X_n) \leq a_n\}$ jsou vzájemně nezávislé. Pro každé $i = 1, \dots, n$ platí, že

$$\{g_i(X_i) \leq a_i\} = \{X_i \in \{g_i \leq a_i\}\}.$$

Dále platí, že $\{g_i \leq a_i\} \in \mathcal{B}$ pro každé $i = 1, \dots, n$. Aplikací předchozí věty tedy ihned dostáváme, že

$$\{X_1 \in \{g_1 \leq a_1\}\}, \dots, \{X_n \in \{g_n \leq a_n\}\}$$

jsou vzájemně nezávislé náhodné jevy. Tvrzení je tedy důsledkem předchozích dvou pozorování a toho, že $a_1, \dots, a_n \in \mathbb{R}$ byly voleny libovolně. □

Sdružená pravděpodobnostní funkce a nezávislost

Věta (Nezávislost diskrétních náhodných veličin)

Diskrétní náhodné veličiny X, Y s pravděpodobnostními funkcemi f_X a f_Y jsou nezávislé právě tehdy, když $f_{X,Y}(a, b) = f_X(a) \cdot f_Y(b)$, pro libovolné $a, b \in \mathbb{R}$.

Důkaz.

Nechť X a Y jsou nezávislé veličiny, pak pro libovolné $a, b \in \mathbb{R}$ platí:

$$\begin{aligned} f_{X,Y}(a, b) &= P(\{X = a\} \cap \{Y = b\}) \\ &= P(\{X = a\}) \cdot P(\{Y = b\}) = f_X(a) \cdot f_Y(b). \end{aligned}$$

Obráceně, necht' platí $f_{X,Y}(a, b) = f_X(a) \cdot f_Y(b)$ pro všechna $a, b \in \mathbb{R}$. Platí:

$$\begin{aligned} P(\{X \leq a\}) \cdot P(\{Y \leq b\}) &= \sum_{x \leq a} f_X(x) \cdot \sum_{y \leq b} f_Y(y) \\ &= \sum_{x \leq a} \left(\sum_{y \leq b} f_Y(y) \cdot f_X(x) \right) = \sum_{x \leq a} \sum_{y \leq b} (f_Y(y) \cdot f_X(x)) \\ &= \sum_{x \leq a} \sum_{y \leq b} f_{X,Y}(x, y) = P(\{X \leq a\} \cap \{Y \leq b\}). \end{aligned}$$



Příklad (Nezávislé diskrétní náhodné veličiny)

Mějme diskrétní náhodné veličiny X a Y se sdruženou pravděpodobnostní funkcí

$$f_{X,Y}(x, y) = \frac{x \cdot y^2}{30} \quad \text{pokud } x \in \{1, 2, 3\} \text{ a } y \in \{1, 2\},$$

a $f_{X,Y}(x, y) = 0$ ve všech ostatních případech.

Úkol: Vyšetřete, jestli jsou X a Y nezávislé.

Řešení: Marginální rozdělení pravděpodobnosti veličin X a Y jsou

$$f_X(x) = \sum_{y=1}^2 \frac{x \cdot y^2}{30} = \frac{x}{30} + \frac{4x}{30} = \frac{x}{6} \quad \text{pro } x \in \{1, 2, 3\},$$

$$f_Y(y) = \sum_{x=1}^3 \frac{x \cdot y^2}{30} = \frac{y^2}{30} + \frac{2y^2}{30} + \frac{3y^2}{30} = \frac{y^2}{5} \quad \text{pro } y \in \{1, 2\}.$$

Zřejmě $f_{X,Y}(x, y) = f_X(x) \cdot f_Y(y)$ pro každé $x, y \in \mathbb{R}$, to jest X a Y jsou nezávislé.

Příklad (Nezávislé diskrétní náhodné veličiny)

Mějme diskrétní náhodné veličiny X a Y se sdruženou pravděpodobnostní funkcí

$$f_{X,Y}(x, y) = \frac{x + y}{21}, \quad \text{pokud } x \in \{1, 2, 3\} \text{ a } y \in \{1, 2\},$$

a $f_{X,Y}(x, y) = 0$ ve všech ostatních případech.

Úkol: Vyšetřete, jestli jsou X a Y nezávislé.

Řešení: Marginální rozdělení pravděpodobnosti veličin X a Y jsou

$$f_X(x) = \sum_{y=1}^2 \frac{x + y}{21} = \frac{x + 1}{21} + \frac{x + 2}{21} = \frac{2x + 3}{21} \quad \text{pro } x \in \{1, 2, 3\},$$

$$f_Y(y) = \sum_{x=1}^3 \frac{x + y}{21} = \frac{6 + 3y}{21} \quad \text{pro } y \in \{1, 2\}.$$

To jest například $f_{X,Y}(1, 1) = \frac{2}{21} \neq \frac{5}{49} = \frac{5}{21} \cdot \frac{9}{21} = f_X(1) \cdot f_Y(1)$, což znamená že náhodné veličiny X a Y jsou závislé.

Příklad (Rychlé vyšetření nezávislosti diskrétních náhodných veličin)

Mějme diskrétní náhodné veličiny X a Y se sdruženou pravděpodobnostní funkcí

$$f_{X,Y}(x,y) = \frac{x \cdot y^2}{13} \quad \text{pro } \langle x, y \rangle \in \{\langle 1, 1 \rangle, \langle 1, 2 \rangle, \langle 2, 2 \rangle\}.$$

a $f_{X,Y}(x,y) = 0$ ve všech ostatních případech.

Úkol: Vyšetřete, jestli jsou X a Y nezávislé.

Řešení: Marginální rozdělení pravděpodobnosti veličin X a Y jsou

$$f_X(x) = \begin{cases} \frac{5}{13} & \text{pro } x = 1, \\ \frac{8}{13} & \text{pro } x = 2, \end{cases} \quad f_Y(y) = \begin{cases} \frac{1}{13} & \text{pro } y = 1, \\ \frac{12}{13} & \text{pro } y = 2. \end{cases}$$

Odtud $f_{X,Y}(2,1) = 0 \neq \frac{8}{169} = \frac{8}{13} \cdot \frac{1}{13} = f_X(2) \cdot f_Y(1)$, veličiny jsou *závislé*.

Obecná (kratší) úvaha: $S = \{\langle x, y \rangle \mid f_{X,Y}(x,y) > 0\}$ není ve tvaru kartézského součinu dvou podmnožin \mathbb{R} . V tom případě zřejmě musí existovat $x, y \in \mathbb{R}$ tak, že $f_{X,Y}(x,y) = 0$ a $f_X(x) > 0$ a $f_Y(y) > 0$, což znamená, že X a Y jsou *závislé*.

Sdružená funkce hustoty a nezávislost

Věta (Nezávislost absolutně spojitých náhodných veličin)

Absolutně spojité náhodné veličiny X, Y se sdruženou funkcí hustoty $f_{X,Y}$ jsou nezávislé právě tehdy, když $f_{X,Y}(a, b) = f_X(a) \cdot f_Y(b)$, pro libovolné $a, b \in \mathbb{R}$.

Důkaz.

Prokazuje se užitím Fubiniho věty a faktů

$$\begin{aligned} P(\{X \leq a\}) \cdot P(\{Y \leq b\}) &= \int_{-\infty}^a f_X(x) \, dx \cdot \int_{-\infty}^b f_Y(y) \, dy \\ &= \int_{-\infty}^b \int_{-\infty}^a f_X(x) \cdot f_Y(y) \, dx \, dy, \end{aligned}$$

$$P(\{X \leq a\}) \cap P(\{Y \leq b\}) = \int_{-\infty}^b \int_{-\infty}^a f_{X,Y}(x, y) \, dx \, dy.$$



Příklad (Nezávislé absolutně spojitě náhodné veličiny)

Problém: Mějme absolutně spojitě náhodné veličiny se sdruženou hustotou

$$f_{X,Y}(x,y) = c \cdot e^{x+y}, \quad \text{pokud } x, y \leq 0,$$

a $f_{X,Y}(x,y) = 0$ ve všech ostatních případech.

Úkol: Stanovte hodnotu $c \in \mathbb{R}$ a určete, jestli jsou X a Y nezávislé.

Řešení: Nejprve z vlastností funkce hustoty stanovíme konstantu $c \in \mathbb{R}$.

$$1 = P_{X,Y}(\mathbb{R}^2) = \int_{-\infty}^{\infty} \int_{-\infty}^{\infty} c \cdot e^{x+y} \, dy \, dx = c \cdot \left(\int_{-\infty}^{\infty} e^{x+y} \, dx \right)^2 = c.$$

Marginální funkce hustoty f_X a f_Y mají potom tvar:

$$f_X(x) = \int_{-\infty}^{\infty} e^{x+y} \, dy = e^x, \quad f_Y(y) = \int_{-\infty}^{\infty} e^{x+y} \, dx = e^y.$$

X a Y jsou nezávislé, protože $f_{X,Y}(x,y) = f_X(x) \cdot f_Y(y)$ pro každé $x, y \in \mathbb{R}$.

Kovariance a korelační koeficient

Definice (Kovariance a korelační koeficient náhodných veličin)

Mějme náhodné veličiny X a Y . Potom

- ❶ Pokud jsou μ_X a μ_Y střední hodnoty veličin X a Y , pak

$$\text{Cov}(X, Y) = \sigma_{X,Y} = E((X - \mu_X) \cdot (Y - \mu_Y))$$

nazýváme **kovariance** náhodných veličin X a Y (*angl.: covariance*);

- ❷ Pokud $\sigma_X^2 > 0$ a $\sigma_Y^2 > 0$, pak

$$\text{Cor}(X, Y) = \rho_{X,Y} = \frac{\text{Cov}(X, Y)}{\sigma_X \cdot \sigma_Y}$$

se nazývá **korelační koeficient** veličin X a Y (*angl.: correlation coefficient*).

Poznámka: Pro $\mathbf{X}(\omega) = \langle X(\omega), Y(\omega) \rangle$ a $g(x, y) = (x - \mu_X) \cdot (y - \mu_Y)$ máme

$$\text{Cov}(X, Y) = E(g(\mathbf{X})).$$

Věta (Střední hodnota součinu náhodných veličin)

$$E(XY) = \mu_X\mu_Y + \rho_{X,Y}\sigma_X\sigma_Y = \mu_X\mu_Y + \text{Cov}(X, Y).$$

Důkaz.

Užitím faktu, že E je lineární operátor dostáváme:

$$\begin{aligned} E((X - \mu_X)(Y - \mu_Y)) &= E(XY - \mu_X Y - \mu_Y X + \mu_X \mu_Y) = \\ &= E(XY) - \mu_X E(Y) - \mu_Y E(X) + \mu_X \mu_Y = \\ &= E(XY) - \mu_X \mu_Y - \mu_Y \mu_X + \mu_X \mu_Y = E(XY) - \mu_X \mu_Y. \end{aligned}$$

Jelikož $\rho_{X,Y} = \frac{\text{Cov}(X, Y)}{\sigma_X \sigma_Y} = \frac{E(XY) - \mu_X \mu_Y}{\sigma_X \sigma_Y}$, vyjádřením $E(XY)$ dostáváme:

$$E(XY) = \mu_X \mu_Y + \rho_{X,Y} \sigma_X \sigma_Y.$$



Důsledek: Střední hodnota součinu XY je rovna součinu středních hodnot X a Y zvětšenému o kovarianci $\text{Cov}(X, Y) = \rho_{X,Y} \sigma_X \sigma_Y$.

Příklad (Výpočet korelačního koeficientu dvou náhodných veličin)

Mějme diskrétní náhodné veličiny se sdruženou pravděpodobnostní funkcí

$$f_{X,Y}(x,y) = \frac{x+2y}{18}, \quad \text{pro } x \in \{1,2\} \text{ a } y \in \{1,2\},$$

$f_{X,Y}(x,y) = 0$ v ostatních případech. Střední hodnota a rozptyl marginálních náhodných veličin jsou následující:

$$\mu_X = \frac{14}{9}, \quad \sigma_X^2 = \frac{20}{81}, \quad \mu_Y = \frac{29}{18}, \quad \sigma_Y^2 = \frac{77}{324}.$$

Kovarianci veličin X a Y stanovíme pomocí vztahu z předchozího tvrzení

$$\text{Cov}(X,Y) = \sum_{x=1}^2 \sum_{y=1}^2 xy \cdot \frac{x+2y}{18} - \frac{14}{9} \cdot \frac{29}{18} = -\frac{1}{162}.$$

Potom má korelační koeficient $\rho_{X,Y}$ hodnotu

$$\rho_{X,Y} = \frac{-1/162}{\sqrt{(20/81) \cdot (77/324)}} \approx -0.025.$$

Příklad (Kovariance nezávislých diskrétních veličin)

Problém: Mějme nezávislé diskrétní náhodné veličiny X a Y .

Úkol: Stanovte kovarianci X a Y .

Řešení: S využitím faktu $f_{X,Y}(x, y) = f_X(x) \cdot f_Y(y)$ máme:

$$\begin{aligned} E(u(X) \cdot v(Y)) &= \sum_{x \in \mathbb{R}} \sum_{y \in \mathbb{R}} u(x) \cdot v(y) \cdot f_{X,Y}(x, y) = \\ &= \sum_{x \in \mathbb{R}} \sum_{y \in \mathbb{R}} u(x) \cdot v(y) \cdot f_X(x) \cdot f_Y(y) = \\ &= \sum_{x \in \mathbb{R}} u(x) \cdot f_X(x) \cdot \sum_{y \in \mathbb{R}} v(y) \cdot f_Y(y) = \\ &= E(u(X)) \cdot E(v(Y)). \end{aligned}$$

To jest, ve speciálním případě:

$$\text{Cov}(X, Y) = E((X - \mu_X)(Y - \mu_Y)) = E(X - \mu_X) \cdot E(Y - \mu_Y) = 0 \cdot 0 = 0.$$

Důsledek: Pokud jsou X a Y nezávislé, jejich kovariance je nulová.

Pozor: Opačné tvrzení neplatí: existují závislé veličiny s nulovou kovariancí. (!!)

Lineární regresní funkce

- Vyšetřování (*lineární*) *závislosti* jedné náhodné veličiny na druhé;
- jako v případě výběrů (PŘEDNÁŠKA 2), ale pracujeme s *náhodnými veličinami*.

Nalezení regresní přímky ve smyslu metody nejmenších čtverců

Předpokládejme, že máme náhodné veličiny X a Y .

- 1 Uvažujeme body $\langle x, y \rangle$ v prostoru (s jejich pravděpodobnostmi);
- 2 speciálně lze uvažovat bod $\langle \mu_X, \mu_Y \rangle$ daný středními hodnotami X a Y ;
- 3 přímky procházející bodem $\langle \mu_X, \mu_Y \rangle$ splňují $y - \mu_Y = b \cdot (x - \mu_X)$;
- 4 uvažujme bod $\langle x_0, y_0 \rangle$, čtverec jeho vzdálenosti od přímky $y = b \cdot (x - \mu_X) + \mu_Y$ je $(y_0 - \mu_Y - b \cdot (x_0 - \mu_X))^2$.
- 5 Očekávaná střední vzdálenost bodů od přímky je tedy

$$E((Y - \mu_Y - b \cdot (X - \mu_X))^2).$$

- 6 Hledáme proto $b \in \mathbb{R}$, které minimalizuje $K(b) = E((Y - \mu_Y - b \cdot (X - \mu_X))^2)$.

Vyjádření lineární regresní funkce

Zjednodušením tvaru funkce K a vyjádřením pomocí korelačního koeficientu:

$$\begin{aligned} K(b) &= E((Y - \mu_Y - b \cdot (X - \mu_X))^2) = \\ &= E((Y - \mu_Y)^2 - 2b(X - \mu_X)(Y - \mu_Y) + b^2(X - \mu_X)^2) = \\ &= \sigma_Y^2 - 2b\sigma_{X,Y} + b^2\sigma_X^2 = \sigma_Y^2 - 2b\rho_{X,Y}\sigma_X\sigma_Y + b^2\sigma_X^2. \end{aligned}$$

První derivace funkce K je následující:

$$K'(b) = -2\rho_{X,Y}\sigma_X\sigma_Y + 2b\sigma_X^2$$

To znamená, že hledané minimum je $b = \frac{\rho_{X,Y} \cdot \sigma_Y}{\sigma_X}$ (platí $K''(b) = 2\sigma_X^2 > 0$).

Věta (Tvar regresní přímky ve smyslu metody nejmenších čtverců)

$$y = \mu_Y + \rho_{X,Y} \cdot \frac{\sigma_Y}{\sigma_X} \cdot (x - \mu_X).$$



Příklad (Lineární regresní funkce)

Mějme diskrétní náhodné veličiny se sdruženou pravděpodobnostní funkcí

$$f_{X,Y}(x,y) = \frac{x+2y}{18}, \quad \text{pro } x \in \{1, 2\} \text{ a } y \in \{1, 2\},$$

$f_{X,Y}(x,y) = 0$ v ostatních případech.

Z předchozího příkladu víme, že

$$\mu_X = \frac{14}{9}, \quad \sigma_X^2 = \frac{20}{81}, \quad \mu_Y = \frac{29}{18}, \quad \sigma_Y^2 = \frac{77}{324}.$$

Dále máme stanovenou hodnotu korelačního koeficientu:

$$\rho_{X,Y} = \frac{\text{Cov}(X,Y)}{\sqrt{(20/81) \cdot (77/324)}} \approx -0.025.$$

Lineární regresní funkce je proto ve tvaru:

$$y = \mu_Y + \rho_{X,Y} \cdot \frac{\sigma_Y}{\sigma_X} \cdot (x - \mu_X) = \frac{14}{9} + \frac{-0.025\sqrt{77/324}}{\sqrt{20/81}} \cdot \left(x - \frac{14}{9}\right).$$

Podmíněná rozdělení

S využitím podmíněné pravděpodobnosti (PŘEDNÁŠKA 4) lze psát

$$P(\{X \in A\}|\{Y \in B\}) = \frac{P(\{X \in A\} \cap \{Y \in B\})}{P(\{Y \in B\})} = \frac{P_{X,Y}(A, B)}{P_Y(B)}.$$

To nás motivuje k zavedení následujícího pojmu:

Definice (Podmíněné rozdělení náhodné veličiny)

Mějme náhodné veličiny X a Y se sdruženým rozdělením pravděpodobnosti $P_{X,Y}$. Pak pravděpodobnostní míra $P_{X|\{Y \in B\}}$ daná pro každou $A \in \mathcal{B}$ předpisem

$$P_{X|\{Y \in B\}}(A) = \frac{P_{X,Y}(A, B)}{P_Y(B)} \quad \text{pokud } P_Y(B) > 0,$$

je **podmíněné rozdělení** pravděpodobnosti náhodné veličiny X za předpokladu, že náhodná veličina Y nabude hodnoty z $B \in \mathcal{B}$, *angl.: conditional distribution*.

Pojmy související s podmíněným rozdělením

Pro $P_{X|\{Y \in B\}}$ je $F_{X|\{Y \in B\}}$ **podmíněná distribuční funkce** ve tvaru

$$F_{X|\{Y \in B\}}(a) = P_{X|\{Y \in B\}}((-\infty, a]) = P(\{X \leq a\}|\{Y \in B\}) .$$

Pokud je X diskrétní, pak **podmíněná pravděpodobnostní funkce** je ve tvaru

$$f_{X|\{Y \in B\}}(x) = P_{X|\{Y \in B\}}(\{x\}) = P(\{X = x\}|\{Y \in B\}) .$$

Pokud je $P_{X|\{Y \in B\}}$ absolutně spojitá pravděpodobnostní míra s hustotou f , pak se f označuje $f_{X|\{Y \in B\}}$ a nazývá se **podmíněná funkce hustoty**. V důsledku:

$$P_{X|\{Y \in B\}}(A) = \int_A f_{X|\{Y \in B\}} dm .$$

Pokud je $P_Y(B) > 0$, **podmíněná střední hodnota** X za předpokladu $\{Y \in B\}$ je

$$E(X|\{Y \in B\}) = \frac{E(X \cdot \mathbf{1}_{\{Y \in B\}})}{P_Y(B)} , \quad \text{kde } \mathbf{1}_{\{Y \in B\}} \text{ je indikátorová funkce.}$$

Příklad (Podmíněné rozdělení pravděpodobnosti)

Mějme diskrétní náhodné veličiny X a Y se sdruženou pravděpodobnostní funkcí

$$f_{X,Y}(x,y) = \frac{x+y}{21} \quad \text{pro } x \in \{1, 2, 3\} \text{ a } y \in \{1, 2\},$$

$f_{X,Y}(x,y) = 0$ ve všech ostatních případech.

Marginální pravděpodobnostní funkce f_X a f_Y jsou následující:

$$f_X(x) = \frac{2x+3}{21} \text{ pro } x \in \{1, 2, 3\}; \quad f_Y(y) = \frac{6+3y}{21} \text{ pro } y \in \{1, 2\}.$$

Podmíněnou pravděpodobnostní funkci $f_{X|Y=y}$ lze vyjádřit

$$f_{X|Y=y}(x) = P(\{X=x\}|\{Y=y\}) = \frac{f_{X,Y}(x,y)}{f_Y(y)} = \frac{(x+y)/21}{(6+3y)/21} = \frac{x+y}{6+3y}.$$

Například tedy máme

$$P(\{X \geq 2\}|\{Y=2\}) = f_{X|Y=2}(2) + f_{X|Y=2}(3) = \frac{4}{12} + \frac{5}{12} = \frac{3}{4}.$$

Příklad (Podmíněné střední hodnoty)

Problém: Uvažujme náhodné veličiny X a Y z předchozího příkladu.

Úkol: Stanovte podmíněnou střední hodnotu X za předpokladu, že $\{Y = 2\}$.

Řešení: Jelikož je X diskrétní, existuje spočetná $C \subseteq \mathbb{R}$ tak, že

$$\begin{aligned} E(X|\{Y \in B\}) &= \frac{E(X \cdot \mathbf{1}_{\{Y \in B\}})}{P_Y(B)} = \frac{1}{P_Y(B)} \sum_{x \in C} x \cdot P(\{X \cdot \mathbf{1}_{\{Y \in B\}} = x\}) \\ &= \sum_{x \in C} x \cdot \frac{P(\{X = x\} \cap \{Y \in B\})}{P_Y(B)} = \sum_{x \in C} x \cdot f_{X|\{Y \in B\}}(x). \end{aligned}$$

Speciálně pro $B = \{y\}$ dostáváme:

$$E(X|\{Y = y\}) = \sum_{x \in C} x \cdot f_{X|\{Y=y\}}(x) = \sum_{x \in C} x \cdot \frac{f_{X,Y}(x, y)}{f_Y(y)}.$$

Případě předchozího příkladu pro $y = 2$ dostáváme:

$$E(X|\{Y = 2\}) = 1 \cdot f_{X|\{Y=2\}}(1) + 2 \cdot f_{X|\{Y=2\}}(2) + 3 \cdot f_{X|\{Y=2\}}(3) = \frac{13}{6}.$$

Příklad (Jeden politicky nekorektní příklad)

Problém: Malý podnik zaměstnává 100 mužů a 100 žen a výplaty všech zaměstnanců jsou buď 20 000 Kč nebo 30 000 Kč nebo 50 000 Kč. Muži zaměstnaní v podniku mají následující výplaty: 20 z nich má 20 000 Kč, 20 z nich má 30 000 Kč a zbývajících 60 má 50 000 Kč. Průměrný plat muže v podniku je tedy:

$$\frac{20 \cdot 20\,000 + 20 \cdot 30\,000 + 60 \cdot 50\,000}{100} = 40\,000 \text{ Kč.}$$

Ženy zaměstnané v podniku vydělávají následovně: 60 vydělává 20 000, 20 vydělává 30 000 a zbývajících 20 vydělává 50 000, což dává průměrnou hodnotu

$$\frac{60 \cdot 20\,000 + 20 \cdot 30\,000 + 20 \cdot 50\,000}{100} = 28\,000 \text{ Kč.}$$

Otázka: Jak máme tento výsledek interpretovat?

Odpověď statistika: **Nijak.** (Alespoň ne bez dodatečné informace.)

Příklad (Simpsonův paradox)

Pokud budeme uvažovat *dodatečnou dimenzi dat* (počet let v zaměstnání), situace z předchozího příkladu může vypadat následovně:

	<i>výplata</i>	<i>1 rok</i>	<i>5 let</i>	<i>celkem</i>
muži	20 000	15	5	20
	30 000	5	15	20
	50 000	0	60	60
průměr		22 500	44 375	40 000
ženy	20 000	60	0	60
	30 000	5	15	20
	50 000	5	15	20
průměr		23 750	45 000	28 000

Ačkoliv mají muži vyšší celkovou průměrnou mzdu než ženy, v rámci obou skupin se stejnou dobou praxe mají ženy vyšší průměrnou mzdu než muži.

Příklad (Generování pseudonáhodných čísel ruletovou metodou)

Problém: Máme diskrétní náhodnou veličinu X takovou, že $P_X(C) = 1$ pro konečnou množinu $C \subseteq \mathbb{R}$. Úkolem je generovat (na počítači) pseudonáhodná čísla, která mají stejné rozdělení, jako veličina X (simulace náhodné veličiny X).

Většina programovacích jazyků disponuje pouze funkcí pro generování pseudonáhodných čísel odpovídající (*diskrétnímu*) *uniformnímu* rozdělení.

Pokud pro konečnou $C \subseteq \mathbb{R}$ platí $P_X(C) = 1$, lze použít následující *princip ruletového výběru*:

- 1 Označme $C = \{x_1, \dots, x_k\}$ tak, že $f_X(x_i) > 0$ a $x_1 < x_2 < \dots < x_k$;
- 2 vygenerujeme uniformní pseudonáhodné číslo $p \in [0, 1]$;
- 3 najdeme nejmenší index $i = 1, \dots, k$ splňující podmínku $p \leq \sum_{n=1}^i f_X(x_n)$;
- 4 vrátíme hodnotu x_i jako výsledek.

Otázka: Jak postupovat pro obecná X ?

Věta (O inverzní transformaci)

Mějme náhodnou veličinu X s rozdělením $U(0, 1)$. Pak pro libovolnou distribuční funkci F platí, že náhodná veličina $F^{-}(X)$ má distribuční funkci F .

Důkaz.

Distribuční funkce náhodné veličiny $F^{-}(X)$ je ve tvaru

$$F_{F^{-}(X)}(a) = P_{F^{-}(X)}((-\infty, a]) = P(\{F^{-}(X) \leq a\}) = P(\{X \in \{F^{-} \leq a\}\}).$$

Pokud si nyní uvědomíme, že $\{F^{-} \leq a\} = \{x \in \mathbb{R} \mid F^{-}(x) \leq a\}$ a využijeme faktu, že $x \leq F(a)$ platí právě tehdy, když $F^{-}(x) \leq a$ (PŘEDNÁŠKA 7), pak

$$\{F^{-} \leq a\} = \{x \in \mathbb{R} \mid F^{-}(x) \leq a\} = \{x \in \mathbb{R} \mid x \leq F(a)\} = (-\infty, F(a)].$$

Dosazením do předchozí rovnosti a využitím faktu, že X má uniformní rozdělení $U(0, 1)$, dostáváme:

$$\begin{aligned} F_{F^{-}(X)}(a) &= P(\{X \in \{F^{-} \leq a\}\}) = P(\{X \in (-\infty, F(a)]\}) \\ &= P(\{0 \leq X \leq F(a)\}) = F(a). \end{aligned}$$



Příklad (Použití inverzní transformace)

Předchozí věta dává následující *postup generování pseudonáhodných čísel*:

- 1 vygenerujeme *uniformní pseudonáhodné číslo* $x \in [0, 1]$;
- 2 vypočítej *výslednou hodnotu* $F^{-}(x)$.

Použitelné v případech, kdy F^{-} má jednoduché explicitní vyjádření.

Poznámka: Nutné mít kvalitní generátor uniformních (pseudo)náhodných čísel.

Implementace ve standardních knihovnách C99 (ISO/IEC 9899)

```
#include <stdlib.h>

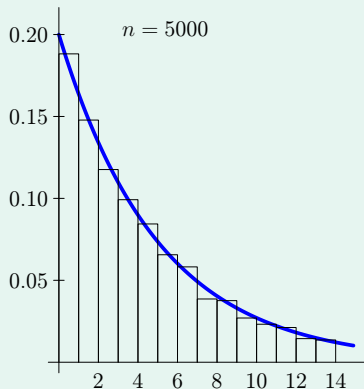


double random_u01 (void) {
    /* 0x7FFFFFFF =  $2^{31} - 1$  */
    return random () / ((double) 0x7FFFFFFF);
}
```

Příklad (Pseudonáhodná čísla z exponenciálního rozdělení)

Mějme náhodnou veličinu X , která má exponenciální rozdělení s parametrem $\mu = \theta$. Pak kvantilová funkce F_X^- náhodné veličiny X je ve tvaru:

$$F_X^-(p) = -\theta \cdot \ln(1 - p), \quad \text{pro } p \in [0, 1).$$

Příklad: Pro X s parametrem $\theta = 5$ a odpovídající F_X^- použijeme předchozí postup:



Věta (Základní věta simulace náhodných veličin)

Mějme absolutně spojitou náhodnou veličinu X s hustotou f_X a uvažujme dvourozměrný absolutně spojitý náhodný vektor \mathbf{X} jehož hustota $f_{\mathbf{X}}$ je

$$f_{\mathbf{X}}(x, y) = \begin{cases} 1 & \text{pokud } 0 < y < f_X(x), \\ 0 & \text{jinak.} \end{cases}$$

Pak $f_X = f_{\pi_1(\mathbf{X})}$, to jest f_X je marginální hustota \mathbf{X} . Pokud je navíc f_X shora omezená hodnotou nějakého $m \in \mathbb{R}$ a f_X nabývá nenulových hodnot pouze na intervalu (a, b) , pak platí, že

$$P(\{X \leq x\}) = P(\{U \leq x\} | \{V \leq f_X(U)\}),$$

kde U má rozdělení $U(a, b)$ a V má rozdělení $U(0, m)$.

Důkaz (začátek).

První část tvrzení je triviální, protože:

$$f_{\pi_1(\mathbf{X})}(x) = \int_{-\infty}^{\infty} f_{\mathbf{X}}(x, y) \, dy = \int_0^{f_X(x)} 1 \, dy = f_X(x).$$

Důkaz (dokončení).

Rozepsáním podmíněné pravděpodobnosti z druhé části tvrzení dostáváme

$$P(\{U \leq x\} | \{V \leq f_X(U)\}) = \frac{P(\{U \leq x\} \cap \{V \leq f_X(U)\})}{P(\{V \leq f_X(U)\})}.$$

Jelikož $f_{U,V}(u, v)$ má na $(a, b) \times (0, m)$ konstantní nenulovou hodnotu:

$$\frac{P(\{U \leq x\} \cap \{V \leq f_X(U)\})}{P(\{V \leq f_X(U)\})} = \frac{\int_a^x \int_0^{f_X(u)} f_{U,V}(u, v) \, dv \, du}{\int_a^b \int_0^{f_X(u)} f_{U,V}(u, v) \, dv \, du} = \frac{\int_a^x \int_0^{f_X(u)} 1 \, dv \, du}{\int_a^b \int_0^{f_X(u)} 1 \, dv \, du}.$$

Užitím pozorování z první části tvrzení dostáváme:

$$\frac{\int_a^x \int_0^{f_X(u)} 1 \, dv \, du}{\int_a^b \int_0^{f_X(u)} 1 \, dv \, du} = \frac{\int_a^x f_X(u) \, du}{\int_a^b f_X(u) \, du} = \frac{\int_a^x f_X(u) \, du}{1} = \int_a^x f_X(u) \, du = P(\{X \leq x\}).$$



Aplikace věty: Lze generovat pseudonáhodná čísla pouze pomocí funkce hustoty f_X a generátoru uniformních pseudonáhodných čísel. (!!)

Implementace

Algoritmus (generování pseudonáhodných čísel pomocí funkce hustoty)

```
(defun density-random (f a b m)
  "Generate random number from interval (A,B) according to
  distribution with density F bounded by [0,M].\"
  (loop
    for u := (+ a (random (float (- b a) 1L0)))
    for v := (random (float m 1L0))
    when (<= v (funcall f u)) do
      (return u)))
```

Poznámka:

- používá se v případech, kdy F_X^- nelze jednoduše vyjádřit;
- metoda inverzní funkce se naopak používá, pokud lze F_X^- jednoduše počítat.

Přednáška 8: Závěr

Pojmy:

- náhodný vektor, vícerozměrné Borelovské jevové pole,
- sdružené rozdělení pravděpodobnosti, marginální rozdělení pravděpodobnosti
- nezávislost náhodných veličin, kovariance, korelační koeficient
- podmíněná rozdělení, inverzní transformace, pseudonáhodná čísla

Použité zdroje:



Capinski M., Zastawniak T. J.: *Probability Through Problems*
Springer 2001, ISBN 978-0-387-95063-1.



Gentle J. E.: *Random Number Generation and Monte Carlo Methods*
Springer 2004, ISBN 978-0-387-00178-4.



Hogg R. V., Tanis E. A.: *Probability and Statistical Inference*
Prentice Hall; 7. vydání 2005, ISBN 978-0-13-146413-1.